

CIÊNCIAS CONTÁBEIS

Métodos Quantitativos

em Ciências Contábeis

Unidade I

Fundamentos de Estatística
e Regressão Linear Simples

Prof. Gustavo Xavier

Da observação à interpretação

Descrever dados, reconhecer a incerteza, construir modelos e avaliar criticamente o que os resultados permitem concluir.

Apostila de estudo, exercícios e práticas orientadas

Versão integrada

Setembro de 2026

Sumário

Apresentação	iii
1 Estatística descritiva e relações entre variáveis	1
1.1 Dados, unidades de análise e somatórios	1
1.2 Medidas de posição e dispersão	3
1.3 Gráficos e distribuição de frequências	5
1.4 Covariância, correlação e interpretação causal	8
Checagem rápida do Módulo 1	11
2 Inferência: o que a amostra permite concluir	12
2.1 População, amostra e erro-padrão	12
2.2 Intervalo de confiança: estimativa e margem de incerteza	14
2.3 Testes de hipóteses, p-valor e decisão	16
Checagem rápida do Módulo 2	18
3 Regressão simples: estimação e interpretação	19
3.1 Como uma reta ajuda a descrever os dados	19
3.2 Mínimos quadrados ordinários: cálculo da reta	21
3.3 Valores ajustados, resíduos e previsão pontual	23
Checagem rápida do Módulo 3	25
4 Regressão simples: inferência e avaliação	26
4.1 Decomposição da variabilidade, R^2 e erro residual	26
4.2 Erros-padrão, teste t e intervalos dos coeficientes	28
4.3 Intervalo da média e intervalo de previsão	30
4.4 Pressupostos, diagnóstico e observações influentes	31
Checklist para avaliar uma regressão	34
Questão integradora	34
A Revisão matemática e medidas descritivas	35

A.1	Sinais, potências e raízes	35
A.2	Somatórios	35
A.3	Por que a variância amostral usa n menos um?	36
A.4	Média ponderada e comparação relativa	36
A.5	Classes desiguais e regra do boxplot	37
A.6	Covariância e correlação: cálculo direto	38
B	Por trás da inferência estatística	39
B.1	Distribuição amostral e propriedades dos estimadores	39
B.2	A correção para população finita	40
B.3	Distribuições normal e t ; fórmula geral do intervalo	40
B.4	P-valor, direção do teste e poder	40
C	Aprofundamentos da regressão simples	42
C.1	Modelo populacional e média condicional	42
C.2	Por que as fórmulas de MQO funcionam?	42
C.3	Decomposição da variação e variância residual	43
C.4	Erros-padrão e inferência dos coeficientes	43
C.5	Fórmulas completas dos intervalos de previsão	43
C.6	Alavancagem, distância de Cook e gráfico Q-Q	44
D	Notação de consulta rápida	46
D.1	Dados, descrição e amostragem	46
D.2	Inferência estatística	46
D.3	Regressão linear simples	47
	Referências	48

Apresentação

Uma controladoria observa custos diferentes entre filiais. Uma equipe de auditoria encontra prazos de pagamento muito dispersos. Um pesquisador pergunta se empresas com maior ativo apresentam maior lucro. Antes de escolher um teste ou executar um programa, é necessário definir a pergunta, a unidade observada, a qualidade dos dados e o alcance da conclusão.

Esta unidade desenvolve esse percurso em quatro módulos. Os exemplos são **fictícios e construídos para fins didáticos**; não representam empresas, alunos ou levantamentos reais. As aplicações contábeis, administrativas e econômicas ilustram métodos, não recomendações de decisão financeira.

Objetivos de aprendizagem

Ao concluir a unidade, o estudante deverá ser capaz de:

- organizar dados, escolher gráficos e calcular medidas de posição, dispersão e associação com as respectivas unidades;
- distinguir população e amostra, parâmetro e estimador, desvio-padrão e erro-padrão, associação e causalidade;
- construir e interpretar intervalos de confiança e testes para uma média;
- estimar uma regressão simples por mínimos quadrados ordinários (MQO), interpretar coeficientes, obter resíduos e produzir previsões;
- avaliar pressupostos, incerteza, influência de observações e limites do R^2 , comunicando resultados sem extrapolar a evidência.

Percurso de aprendizagem

Módulo	Pergunta central	Produto do estudo
1	Como os dados variam juntos?	Tabela, gráfico e síntese descritiva.
2	O que a amostra informa?	Estimativa com incerteza explícita.
3	Qual reta resume a relação?	Equação, resíduos e previsão.
4	Quanto confiar no modelo?	Avaliação crítica e relatório.

Cada tópico começa com uma situação próxima da prática: comparar empresas, acompanhar custos ou analisar prazos. Primeiro vamos entender a pergunta; depois, fazer a conta e explicar o resultado. Não é necessário conhecer cálculo diferencial para acompanhar os quatro capítulos.

Como estudar, mesmo com dificuldade em matemática

Leia o exemplo antes da fórmula. Separe os dados fornecidos, faça uma conta de cada vez e escreva a unidade do resultado. Se aparecer um símbolo novo, procure sua explicação no próprio tópico. As fórmulas são uma forma curta de registrar operações que faremos passo a passo.

Os quatro capítulos formam o percurso principal. Os apêndices são leituras opcionais para quem quiser entender as justificativas matemáticas ou ir além dos cálculos básicos. As notas de rodapé indicam onde encontrá-las.

Ao final de cada tópico há exercícios com respostas e uma prática orientada em Python. Tente resolver antes de olhar o gabarito. O computador serve para conferir e explorar os dados, não para substituir a interpretação.

O caso de **oito empresas, ativo e lucro** acompanha a descrição dos dados. O caso de **horas de estudo e notas** permite acompanhar integralmente os cálculos de regressão. Pequenas bases favorecem o cálculo manual, mas não são suficientes para validar, por si sós, os pressupostos de inferência.

Ferramentas e convenções

Papel, lápis e calculadora com raiz quadrada bastam para os exercícios manuais. Os valores críticos necessários são fornecidos. Use pelo menos quatro casas decimais nos passos intermediários; apresente resultados finais com duas ou três casas e indique unidades. Pequenas diferenças de arredondamento são esperadas. Nos textos, a vírgula é decimal; no código Python, usa-se ponto.

Python é uma ferramenta de conferência, não o objeto da disciplina. Os roteiros utilizam NumPy, pandas, SciPy e Matplotlib em um ambiente onde já estejam disponíveis. Execute cada bloco completo em uma célula ou arquivo; cada prática é autossuficiente. Primeiro antecipe o resultado, depois execute e, por fim, escreva uma interpretação. A opção `ddof=0` divide a soma dos quadrados por n ; `ddof=1`, por $n - 1$ [7]. Essa escolha depende do objetivo estatístico, não de preferência de software.

Como extensão opcional, a pasta `../03-material-didatico/webbook/codigos/` reúne notebooks que acompanham o percurso da unidade: `ch01n2_intro_to_data.ipynb` para organização e descrição de dados. Para inferência, consulte `ch05_confidence_intervals.ipynb` e `ch07_inf_for_numerical_data.ipynb`; para regressão e diagnóstico, consulte `ch08_simple_regression.ipynb` [6]. Eles são material complementar: os blocos desta apostila continuam executáveis com as bases fictícias aqui apresentadas. Ao usar os notebooks, identifique a origem dos dados, as bibliotecas adicionais e a diferença entre uma ilustração computacional e uma conclusão empírica.

Notação de consulta rápida

Símbolo	Significado
N, n	Tamanho da população finita e tamanho da amostra.
i	Índice da observação: $i = 1, \dots, n$.
x_i, y_i	Valores de duas características na observação i .
μ, σ^2, σ	Média, variância e desvio-padrão populacionais.
$\bar{x}, s_x^2, s_x$	Média, variância e desvio-padrão amostrais.
$\hat{\beta}_0, \hat{\beta}_1$	Ponto de partida e inclinação da reta calculada com a amostra.
$\hat{y}_i, e_i$	Valor ajustado e resíduo amostral.
α	Limite escolhido para a decisão de um teste, como 5%.

Estudo e avaliação

Ao encontrar 2^2 , leia “dois ao quadrado”: $2 \times 2 = 4$. Ao encontrar $\sqrt{4}$, procure o número não negativo que, ao quadrado, resulta em 4: a resposta é 2. Em $8/4$, faça $8 \div 4$; em $0,25 \times 100$, obtenha 25%. Essa revisão já resolve boa parte das operações que aparecem adiante.¹

Como proposta de acompanhamento, organize um portfólio com: cálculos manuais justificados; gráficos com títulos, eixos e unidades; interpretação dos resultados; e um breve relatório reproduzível. Em uma avaliação, não basta escrever um número: é necessário explicar o método, as condições de uso e o que não se pode concluir. Esta proposta não estabelece pesos ou calendário.

As leituras básicas são Anderson et al. e Gujarati e Porter [1, 2]; OpenIntro oferece apoio complementar [3]. A nota de aula e a lista da aula inicial estão na pasta `modulo-1/` e são documentos independentes desta apostila.

¹Para rever sinais, somatórios e outras regras de cálculo, consulte o Apêndice A, “Revisão matemática e medidas descritivas”.

Capítulo 1

Estatística descritiva e relações entre variáveis

Objetivo do módulo

Transformar uma tabela em uma descrição inteligível: o que foi observado, onde os valores se concentram, quanto variam e como duas variáveis se associam.

1.1 Dados, unidades de análise e somatórios

Comece pela situação

Um analista reúne o ativo e o lucro anual de oito empresas no mesmo período. Cada linha representa uma empresa; cada coluna descreve uma característica. Sem saber a unidade monetária ou o período, comparar os números seria arriscado.

Tabela 1.1: Ativo e lucro anual de oito empresas fictícias

Empresa	A	B	C	D	E	F	G	H
Ativo x (R\$ milhões)	10	20	30	40	50	60	70	80
Lucro y (R\$ milhões)	1	3	2	5	4	7	6	8

Conceitos e generalização

A **unidade de análise** é aquilo que observamos: aqui, uma empresa. Uma **variável** é uma característica registrada para cada empresa. Uma variável **qualitativa nominal** indica categorias sem ordem, como setor; uma **ordinal**, categorias ordenadas, como risco baixo, médio e alto. Uma variável **quantitativa discreta** resulta de contagem, como número de filiais; uma **contínua** resulta de mensuração, como tempo. Valores monetários são usualmente tratados como contínuos no modelo, embora registrados em unidades monetárias discretas. Um código numérico de empresa é identificador, não quantidade a ser somada.

Corte transversal: várias unidades no mesmo período. **Série temporal**: uma unidade em períodos sucessivos. **Painel**: várias unidades acompanhadas ao longo do tempo. Observações repetidas de uma empresa não devem ser tratadas automaticamente como independentes.

O símbolo $\sum$ significa somar. Por exemplo, para os valores 2, 3, 5, escrever $\sum x_i$ é apenas uma forma curta de escrever $2 + 3 + 5$. A letra i indica a posição do valor na lista e n é a quantidade de valores:

$$\sum_{i=1}^n x_i = x_1 + \cdots + x_n.$$

O cuidado principal é a ordem das contas: $\sum x_i^2$ pede para elevar cada valor ao quadrado e depois somar. Já $(\sum x_i)^2$ pede para somar primeiro e elevar o total ao quadrado. Não são a mesma conta.¹ Quando os limites forem omitidos, some todos os valores da lista.

Exemplo resolvido: as oito empresas

Temos $n = 8$, $\sum x_i = 360$ e $\sum y_i = 36$ milhões de reais. Já $\sum x_i^2 = 20\,400$, enquanto $(\sum x_i)^2 = 129\,600$, em unidades monetárias ao quadrado. Na soma de produtos, cada ativo deve permanecer emparelhado ao lucro da mesma empresa:

$$\sum x_i y_i = 10(1) + 20(3) + 30(2) + 40(5) + 50(4) + 60(7) + 70(6) + 80(8) = 2\,010.$$

Exemplo resolvido: uma transformação de unidade

Para três despesas 2, 3, 5 em milhares de reais, a soma é 10. Convertendo-as para reais, $\sum 1\,000x_i = 1\,000(10) = 10\,000$. Não se alterou a despesa econômica, apenas a unidade de registro.

Exercícios à mão

1. Classifique: setor da empresa; número de empregados; classificação de risco baixo/médio/alto; receita anual. Qual deles é ordinal?
2. Para $x = (1, 2, 4)$, calcule $\sum x_i$, $\sum x_i^2$, $(\sum x_i)^2$ e $\sum(2 + 3x_i)$.
3. Uma base acompanha quatro lojas em três meses, sem faltas. Quantas linhas há no formato loja-mês? Qual a estrutura? A dependência entre linhas da mesma loja desaparece por aumentar o número de linhas?

Resultados para conferência

1. Nominal; discreta; ordinal; quantitativa usualmente tratada como contínua. O risco é ordinal.
2. 7; 21; 49; 27.
3. 12 linhas; painel; não.

Aplicação prática com Python

1. Monte a tabela abaixo. Confira se há oito linhas, unidades compatíveis, identificadores únicos e ausência de valores faltantes.
2. Calcule os totais e a soma de produtos. Compare com 360, 36 e 2 010.
3. Escreva a unidade de análise e explique por que não ordenar cada coluna separadamente: isso destruiria os pares observados.

¹As regras gerais dos somatórios e suas justificativas estão no Apêndice A, seção A.2.


```
import pandas as pd
dados = pd.DataFrame({
    "empresa": list("ABCDEFGH"),
    "ativo": [10, 20, 30, 40, 50, 60, 70, 80],
    "lucro": [1, 3, 2, 5, 4, 7, 6, 8]
})
print(dados.shape, dados.isna().sum())
print(dados["empresa"].is_unique)
print(dados[["ativo", "lucro"]].sum())
print((dados["ativo"] * dados["lucro"]).sum())
```

1.2 Medidas de posição e dispersão

Comece pela situação

Os lucros 1, 3, 2, 5, 4, 7, 6, 8 somam 36. Se fossem repartidos igualmente entre as oito empresas, cada uma receberia 4,5 milhões: essa é a média. Mas uma média não mostra se os lucros estão próximos ou distantes dela.

Conceitos e generalização

Para calcular a **média**, some os valores e divida pela quantidade. Usamos N quando a lista representa toda a população de interesse e n quando representa uma amostra. As letras gregas abaixo são apenas nomes: μ (“mi”) é a média da população; $\bar{x}$ (“x barra”), a da amostra.

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Ordene os valores para calcular a **mediana**: com quantidade ímpar, selecione o termo central; com quantidade par, tire a média dos dois centrais. A **moda** é o valor mais frequente; pode não haver moda ou haver várias. A **média ponderada** leva em conta quantidades diferentes: um lote de três unidades deve pesar mais que um lote de uma unidade. No exemplo a seguir, vamos multiplicar cada preço pela quantidade, somar e dividir pela quantidade total.

O **desvio** é a diferença entre um valor e a média. Se o lucro é 1 e a média é 4,5, o desvio é $1 - 4,5 = -3,5$: esse lucro ficou abaixo da média. Para medir a dispersão, siga quatro passos:

1. Subtraia a média de cada valor.
2. Eleve cada diferença ao quadrado, evitando que sinais opostos se anulem.
3. Some os quadrados e divida pelo divisor adequado: o resultado é a variância.
4. Tire a raiz quadrada da variância: o resultado é o desvio-padrão.

As fórmulas registram exatamente esse roteiro:

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}, \quad s_x^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}, \quad \sigma = \sqrt{\sigma^2}, \quad s_x = \sqrt{s_x^2}.$$

Na primeira fórmula, σ^2 (“sigma ao quadrado”) é a variância da população. Na segunda, s_x^2 é a variância amostral. O divisor $n - 1$ faz uma correção porque a média foi calculada usando a própria amostra.²

²A explicação matemática do divisor $n - 1$ e dos graus de liberdade está no Apêndice A, seção A.3.

Divisor: depende da pergunta

Se as oito empresas constituem todo o universo de interesse, use $N = 8$ para a variância populacional. Se são uma amostra de uma população mais ampla, use $n - 1 = 7$ ao estimar sua variância. Não escolha o divisor pelo tamanho “pequeno” ou “grande” da base.

A amplitude é máximo menos mínimo. Para os quartis, adotaremos a **mediana de cada metade dos dados ordenados**, excluindo a mediana geral quando n for ímpar. O intervalo interquartil é $AIQ = Q_3 - Q_1$. Outras convenções produzem quartis diferentes em amostras pequenas. Para esta primeira leitura, média, mediana e desvio-padrão são o foco. Existe também uma comparação percentual chamada coeficiente de variação, que exige cuidado especial com lucros negativos ou próximos de zero.³

Exemplo resolvido: lucro das oito empresas

Ordenando os lucros, obtemos 1, 2, 3, 4, 5, 6, 7, 8. A média e a mediana são 4,5; não há moda; a amplitude é 7; $Q_1 = 2,5$, $Q_3 = 6,5$ e $AIQ = 4$. Como $\sum (y_i - 4,5)^2 = 42$:

$$\sigma_y^2 = 42/8 = 5,25, \quad \sigma_y \approx 2,291; \quad s_y^2 = 42/7 = 6, \quad s_y \approx 2,449.$$

A variância está em (R\$ milhões)² e o desvio-padrão em R\$ milhões. Para o ativo, $\bar{x} = 45$, a soma dos desvios quadráticos é 4 200, $\sigma_x^2 = 525$ e $s_x^2 = 600$.

Exemplo resolvido: assimetria e ponderação

Nas despesas 2, 2, 3, 3, 20, a média é 6, a mediana é 3 e as modas são 2 e 3. A despesa extrema eleva a média sem alterar a maioria dos valores. Se dois lotes custam R\$ 10 e R\$ 16 por unidade, com quantidades 3 e 1, o custo médio é $(3 \cdot 10 + 1 \cdot 16)/4 = 11,50$, e não 13.

Exercícios à mão

1. Para 2, 4, 4, 6, calcule média, mediana, moda e amplitude.
2. Para os mesmos valores, calcule a soma dos desvios quadráticos, a variância populacional e a amostral, com os desvios-padrão correspondentes.
3. Para 1, 2, 3, 4, 5, 6, 7, 8, obtenha Q_1 , Q_3 e AIQ pela convenção adotada. Depois some 10 a todos os valores: o que ocorre com a média e a variância? E se multiplicar os valores originais por 2?

Resultados para conferência

1. 4; 4; 4; 4. 2. Soma 8; $\sigma^2 = 2$, $\sigma \approx 1,414$; $s^2 = 8/3 \approx 2,667$, $s \approx 1,633$. 3. 2,5; 6,5; 4. Ao somar 10, a média passa de 4,5 para 14,5 e a variância não muda. Ao multiplicar por 2, a média passa a 9 e a variância quadruplica.

Aplicação prática com Python

1. Informe os lucros. Calcule média, mediana e as duas variâncias.

³A fórmula da média ponderada e o coeficiente de variação estão no Apêndice A, seção A.4.

2. Ordene os dados e obtenha os quartis pelas medianas das metades; não confunda essa regra com a interpolação padrão de alguns programas.
3. Substitua 8 por 80 e descreva a sensibilidade da média e da mediana.

```
import numpy as np
lucro = np.array([1, 3, 2, 5, 4, 7, 6, 8], dtype=float)
ordenado = np.sort(lucro)
print(lucro.mean(), np.median(lucro))
print(lucro.var(ddof=0), lucro.var(ddof=1))
print(lucro.std(ddof=0), lucro.std(ddof=1))
print(np.median(ordenado[:4]), np.median(ordenado[4:]))
alterado = lucro.copy()
alterado[-1] = 80
print(alterado.mean(), np.median(alterado))
```

Na alteração, a média sobe para 13,5 e a mediana permanece 4,5.

1.3 Gráficos e distribuição de frequências

Comece pela situação

Após calcular a média do lucro, queremos enxergar a distribuição. Dividindo os lucros em classes de mesma largura, contamos quantas empresas estão em cada faixa. O histograma torna visível o que a média esconde.

Conceitos e generalização


Uma **classe** é uma faixa de valores. A frequência absoluta é a contagem nessa faixa; a frequência relativa é essa contagem dividida pelo total. Por exemplo, duas empresas entre oito representam $2/8 = 0,25 = 25\%$. Cada valor deve entrar em uma única classe, sem que nenhum fique de fora. Adotaremos $[a, b)$: inclui a , exclui b ; a última classe inclui também o limite superior.

- **Barras:** comparam categorias; as barras são separadas.
- **Histograma:** reúne valores quantitativos em intervalos contíguos, isto é, lado a lado. Usaremos faixas de mesma largura e a contagem como altura. Faixas de larguras diferentes exigem outro cuidado.⁴
- **Boxplot:** resume mediana, quartis e valores afastados. Valores muito afastados são sinalizados para investigação, não para exclusão automática. A regra numérica está no mesmo apêndice.
- **Dispersão:** representa pares (x_i, y_i) para investigar forma, direção e pontos atípicos da relação.
- **Linhas:** mostram evolução temporal; exigem uma ordem temporal significativa, não a ordem arbitrária de empresas.

⁴Para entender a altura das barras quando as classes têm larguras diferentes, consulte o Apêndice A, seção A.5.

Exemplo resolvido: histograma dos lucros


As classes $[0, 2)$, $[2, 4)$, $[4, 6)$ e $[6, 8]$ têm frequências 1, 2, 2, 3, respectivamente. As relativas são 12,5%, 25%, 25% e 37,5%. O lucro 2 pertence à segunda classe, não à primeira.



Com apenas oito valores, mudar as classes pode mudar bastante a aparência. Consulte também a tabela original; um histograma não identifica qual empresa gerou cada lucro.

Exemplo resolvido: um histograma com formato de sino

Agora considere outro conjunto: os tempos de conferência de **100 notas fiscais fictícias**. As dez classes têm largura de 2 minutos. As frequências, da esquerda para a direita, são 1, 3, 7, 15, 24, 24, 15, 7, 3, 1 e somam 100.




As barras são mais altas perto de 20 minutos e diminuem nas duas extremidades. Esse formato de sino, aproximadamente simétrico, lembra uma **distribuição normal**. Os dados foram construídos para ilustrar essa forma; em dados reais, o histograma sozinho não comprova normalidade. Nas duas classes centrais, de 18 até menos de 22 minutos, estão $24 + 24 = 48$ notas, ou 48% do total.

Para ler a forma, observe três aspectos: **onde estão as barras mais altas, como os dois lados se comparam e até onde vão as caudas**, as extremidades com poucos valores. Aqui, as barras se espelham em torno de 20 minutos, e as classes se estendem por 10 minutos de cada lado. Em outros conjuntos, uma cauda pode se prolongar mais que a outra, indicando assimetria. Uma cauda mais longa não significa necessariamente mais observações daquele lado: a quantidade é dada pelas frequências.

Exemplo resolvido: comparando simetria e curtose


Simetria: os dois lados têm formas parecidas? Compare os três histogramas abaixo, construídos com frequências fictícias. Todos usam classes de mesma largura e a mesma escala vertical.



- **À esquerda:** a maioria dos valores está na parte direita; a cauda se prolonga para os valores menores.
- **No centro:** as barras de um lado espelham as do outro.
- **À direita:** a maioria dos valores está na parte esquerda; a cauda se prolonga para os valores maiores.

O nome da assimetria acompanha a direção da **cauda**, não a posição das barras mais altas.

Curtose: qual é o peso dos valores muito afastados do centro? Agora, as três distribuições são simétricas. A diferença está na curtose, uma medida muito sensível aos valores extremos. Nos exemplos abaixo, caudas mais leves ou mais pesadas correspondem a curtose menor ou maior que a da normal. Não basta olhar a altura do pico para avaliar a curtose [12].



Para uma comparação justa, os três modelos têm média 0 e desvio-padrão 1. Um valor padronizado igual a 3 está três desvios-padrão acima da média. As barras representam percentuais esperados em classes de largura 0,5, não uma amostra observada; o desenho mostra somente a faixa de -4 a 4.

Observe especialmente as barras além de -3 e 3: quase desaparecem no primeiro gráfico e ficam mais visíveis no terceiro. Nesse último modelo, valores muito afastados do centro têm maior frequência esperada. Assim, uma distribuição pode ser **simétrica e ter curtose alta**. Simetria e curtose descrevem aspectos diferentes da forma.

Exemplo resolvido: ler uma frequência

Voltando ao histograma dos lucros, na última classe estão três das oito empresas. Faça $3 \div 8 = 0,375$ e depois multiplique por 100: são 37,5%. Isso não significa que a empresa de maior lucro detenha 37,5% do lucro total; estamos contando empresas, não somando seus lucros.

Exercícios à mão

1. Escolha um gráfico para setor de atuação, receita mensal e relação entre ativo e lucro.
2. Distribua 1, 2, 2, 3, 4, 6 nas classes $[0, 2)$, $[2, 4)$ e $[4, 6]$. Informe frequências absolutas e relativas e esboce o histograma.
3. Entre dez despesas, quatro estão em $[0, 10)$ e seis em $[10, 20]$. Calcule as porcentagens e indique qual classe tem mais observações.

Resultados para conferência

1. Barras; linhas; dispersão. 2. 1, 3, 2; $1/6, 1/2, 1/3$ (aproximadamente 16,7%, 50%, 33,3%). Barras contíguas de largura 2 com alturas 1, 3, 2. 3. 40% e 60%; a segunda classe tem mais observações.

Aplicação prática com Python

1. Desenhe o histograma com os limites definidos, sem deixar o programa escolher classes automaticamente.
2. Confira as contagens e rotule os eixos com as unidades.
3. Mude para classes $[0, 4)$ e $[4, 8]$; explique quais detalhes desaparecem.

```
import numpy as np
import matplotlib.pyplot as plt
lucro = np.array([1, 3, 2, 5, 4, 7, 6, 8])
limites = [0, 2, 4, 6, 8]
print(np.histogram(lucro, bins=limites)[0])
plt.hist(lucro, bins=limites, edgecolor="black")
plt.xlabel("Lucro (R$ milhoes)")
plt.ylabel("Numero de empresas")
plt.xticks(limites)
plt.show()
```

As novas classes terão contagens 3 e 5. A última classe do NumPy inclui o limite superior, como nesta apostila.

1.4 Covariância, correlação e interpretação causal

Comece pela situação

Empresas acima da média de ativo tendem a estar acima da média de lucro? Para a empresa A, ambos os desvios são negativos; seu produto é positivo. Para a empresa H, ambos são positivos; o produto também é positivo. Somar esses produtos ajuda a identificar a direção da associação.

Conceitos e generalização

Para saber se ativo e lucro variam na mesma direção, compare cada valor com a média de sua coluna. Multiplique os dois desvios da mesma empresa. Dois sinais iguais produzem resultado positivo; sinais diferentes, negativo. Para organizar as contas, usaremos três abreviações:

$$S_{xx} = \sum (x_i - \bar{x})^2, \quad S_{yy} = \sum (y_i - \bar{y})^2, \quad S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}).$$

S_{xx} soma os quadrados dos desvios de x ; S_{yy} faz o mesmo para y ; S_{xy} soma os produtos dos dois desvios. Não são novas operações: são nomes curtos para contas que acabamos de descrever.⁵ A covariância amostral e a correlação de Pearson são

$$s_{xy} = \frac{S_{xy}}{n-1}, \quad r = \frac{s_{xy}}{s_x s_y} = \frac{S_{xy}}{\sqrt{S_{xx} S_{yy}}}, \quad -1 \leq r \leq 1.$$

Para uma população finita completa, a covariância usa divisor N e médias populacionais. A correlação não tem unidade: seu valor é o mesmo em reais ou milhares de reais. Se uma das variáveis não mudar, não podemos calculá-la. Um sinal positivo indica tendência de crescimento conjunto; um sinal negativo, tendência em sentidos opostos. Valores próximos de 1 ou de -1 indicam pontos mais próximos de uma reta. Sempre confira também o gráfico.

Exemplo resolvido: ativo e lucro


Como $\bar{x} = 45$, $\bar{y} = 4,5$, $S_{xx} = 4\,200$, $S_{yy} = 42$:

$$S_{xy} = 122,5 + 37,5 + 37,5 - 2,5 - 2,5 + 37,5 + 37,5 + 122,5 = 390.$$

O primeiro produto, por exemplo, é $(10 - 45)(1 - 4,5) = 122,5$. Com a soma pronta:

$$s_{xy} = \frac{390}{7} \approx 55,714, \quad r = \frac{390}{\sqrt{4\,200 \cdot 42}} = \frac{13}{14} \approx 0,929.$$

Há associação linear positiva acentuada nesta base. A covariância está em (R\$ milhões)²; a correlação não tem unidade.



Exemplo resolvido: correlação zero não é ausência de relação

Para $x = (-1, 0, 1)$ e $y = (1, 0, 1)$, $\bar{x} = 0$, $\bar{y} = 2/3$ e $S_{xy} = 0$, portanto $r = 0$. Ainda assim, $y = x^2$: existe uma relação exata, mas em forma de curva, e não de reta.

⁵As fórmulas diretas da covariância e da correlação, com um exemplo de cálculo, estão no Apêndice A, seção A.6.

Associação não identifica causa

Ativo e lucro podem compartilhar causas, como setor e porte; o lucro também pode financiar ativos futuros. Uma correlação isolada não separa essas explicações. Identificar um efeito causal exige uma estratégia de pesquisa e hipóteses que não são fornecidas pelo valor de r .

Exercícios à mão

1. Para $x = (1, 2, 3)$ e $y = (2, 4, 6)$, obtenha S_{xx} , S_{yy} , S_{xy} , a covariância amostral e r .
2. Se y for multiplicado por 1 000, o que acontece com a covariância e com a correlação do exercício anterior? E se y for constante?
3. Um levantamento encontra $r = 0,90$ entre gasto com auditoria e receita. É válido afirmar que aumentar esse gasto elevará a receita? Dê uma explicação alternativa e proponha algo a investigar antes de concluir.

Resultados para conferência

1. 2, 8, 4; $s_{xy} = 2$; $r = 1$. 2. A covariância passa a 2 000 e $r = 1$; com y constante, r é indefinido. 3. Não. Empresas maiores podem ter simultaneamente maior receita e maior demanda de auditoria; investigar porte, setor e a sequência temporal é um começo, não prova causal.

Aplicação prática com Python

1. Recrie os pares, calcule covariância amostral e correlação e confira 55,714 e 0,929.
2. Produza o gráfico de dispersão antes de interpretar o coeficiente.
3. Repita para $(-1, 0, 1)$ e $(1, 0, 1)$; redija uma frase distinguindo ausência de associação linear e ausência de relação.

```
import numpy as np
import matplotlib.pyplot as plt
ativo = np.array([10, 20, 30, 40, 50, 60, 70, 80])
lucro = np.array([1, 3, 2, 5, 4, 7, 6, 8])
print(np.cov(ativo, lucro, ddof=1)[0, 1])
print(np.corrcoef(ativo, lucro)[0, 1])
plt.scatter(ativo, lucro)
plt.xlabel("Ativo (R$ milhares)")
plt.ylabel("Lucro (R$ milhares)")
plt.show()
print(np.corrcoef([-1, 0, 1], [1, 0, 1])[0, 1])
```


Checagem rápida do Módulo 1

1. Uma nota de crédito AAA, AA ou A é quantitativa ou categórica? Qual é a escala?
2. Por que desvio-padrão zero implica que todos os valores são iguais?
3. O que uma covariância negativa informa? O que ela não informa?
4. Uma correlação de 0,80 prova que X causa Y ?
5. Qual gráfico deve ser examinado antes de calcular a correlação?

Ideia-chave

O estudante está pronto para avançar quando distingue **variabilidade** de **associação** e associação de **causalidade**.

Síntese pessoal. Registre a distinção que considerou mais importante.

Capítulo 2

Inferência: o que a amostra permite concluir

Objetivo do módulo

Aprender a passar da descrição da amostra à afirmação sobre uma população, sem omitir o mecanismo de seleção nem a incerteza dessa passagem.

2.1 População, amostra e erro-padrão

Comece pela situação

Uma equipe quer conhecer o prazo médio de recebimento de todas as faturas de um período, mas examina apenas algumas. Outra equipe, com outra amostra, provavelmente obterá outra média. Essa variação entre amostras é diferente da variação dos prazos entre faturas de uma mesma amostra.

Conceitos e generalização

A **população-alvo** reúne as unidades sobre as quais se deseja concluir; a **amostra** reúne as unidades efetivamente observadas. O cadastro usado na seleção pode não cobrir a população-alvo: entrevistar apenas clientes ativos, por exemplo, exclui os que deixaram a empresa.

Três palavras ajudam a organizar a pergunta:

- **Parâmetro:** o número da população que queremos conhecer, como o prazo médio de todas as faturas, representado por μ .
- **Estimador:** a regra de cálculo, como somar os prazos da amostra e dividir pela quantidade de faturas.
- **Estimativa:** o resultado dessa conta, como 12 dias.

Sortear as unidades ajuda a evitar uma escolha tendenciosa. Selecionar só clientes conhecidos ou faturas atrasadas pode distorcer a resposta. Aumentar a quantidade de dados não corrige esse problema automaticamente.

Imagine várias equipes sorteando amostras da mesma população. As médias obtidas formariam uma lista de resultados possíveis: essa é a ideia de **distribuição amostral**. O **erro-padrão**

resume quanto essas médias variam. Já o desvio-padrão descreve diferenças entre as faturas. São duas perguntas diferentes.

Quando as observações são independentes e vêm de uma mesma população, estimamos o erro-padrão da média assim:

$$EP(\bar{x}) = \frac{s}{\sqrt{n}}.$$

Leia: “desvio-padrão da amostra dividido pela raiz da quantidade de observações”. Se o desvio-padrão populacional σ for conhecido, ele ocupa o lugar de s .¹

Quando essa conta pede cuidado?

Independência significa que conhecer uma observação não traz informação sobre o resultado de outra. Faturas do mesmo cliente ou dados de meses seguidos podem não ser independentes. Examinar uma grande parte de uma população pequena também exige um ajuste.^a

^aA correção para uma população finita está no Apêndice B, seção B.2.

Exemplo resolvido: a precisão da média

Suponha um desvio-padrão populacional de 4 dias e observações independentes da mesma população. Com $n = 4$, o erro-padrão é $4/\sqrt{4} = 2$ dias. Com $n = 16$, é $4/\sqrt{16} = 1$ dia. Quadruplicar n reduz o erro-padrão à metade; não reduz à metade a dispersão dos prazos individuais.

Exemplo resolvido: calcular com dados de uma amostra

Uma amostra de 16 faturas tem desvio-padrão de 8 dias. Primeiro, $\sqrt{16} = 4$; depois, $8 \div 4 = 2$. O erro-padrão estimado é 2 dias. Isso não quer dizer que os prazos individuais fiquem todos a dois dias da média: o valor se refere à precisão da média estimada, e não a cada fatura.

Exercícios à mão

1. Em uma população de 2 000 faturas, foram sorteadas 25 e o prazo médio observado foi 18 dias. Identifique população, amostra, parâmetro e estimativa.
2. Sob independência, com $s = 12$ e $n = 36$, estime o erro-padrão da média. Se s permanecer aproximadamente igual, qual n reduziria o erro-padrão a 1?
3. Duas equipes têm amostras com o mesmo desvio-padrão. Uma examinou 9 faturas e a outra, 36. Sob as mesmas condições de amostragem, qual tem menor erro-padrão? Se ambas consultassem apenas faturas atrasadas, isso permitiria concluir sobre todas as faturas?

Resultados para conferência

1. As 2 000 faturas; as 25 sorteadas; a média populacional μ ; $\bar{x} = 18$ dias.
2. 2; $n = 144$.
3. A equipe com 36 faturas: seu erro-padrão é metade do outro. Não: a escolha apenas de faturas atrasadas continua excluindo parte da população.

¹Para a explicação matemática da distribuição amostral, do erro-padrão e das propriedades dos estimadores, consulte o Apêndice B, seção B.1.

Aplicação prática com Python

1. Peça ao computador que sorteie 10 000 pares da lista 2, 4, 6. “Com reposição” significa que o mesmo valor pode sair nas duas retiradas. A semente é um número que permite repetir a mesma simulação.
2. Calcule a média de cada amostra e o desvio-padrão dessas médias. Compare com os resultados esperados: média 4 e erro-padrão próximo de 1,155.
3. Repita com tamanho 8. O erro-padrão teórico passa a 0,577. Explique o que foi reduzido. A conta que justifica esses valores está no Apêndice B.

```
import numpy as np
gerador = np.random.default_rng(262)
populacao = np.array([2, 4, 6])
amostras = gerador.choice(populacao, size=(10000, 2), replace=True)
medias = amostras.mean(axis=1)
print(medias.mean(), medias.std(ddof=0))
print(populacao.mean(), populacao.std(ddof=0) / np.sqrt(2))
```

Resultados simulados oscilam ao redor dos valores teóricos; essa diferença não é necessariamente erro de programação.

2.2 Intervalo de confiança: estimativa e margem de incerteza

Comece pela situação

Uma amostra de prazos produz média de 10 dias. Relatar apenas “10” esconde que outra amostra poderia produzir 9 ou 11. Um intervalo combina a estimativa central com uma margem baseada na variabilidade amostral.

Conceitos e generalização

Um **intervalo de confiança** combina uma estimativa com uma margem de incerteza. Para uma média, a conta tem a mesma estrutura nos dois limites:

$$\text{margem} = t_{\text{crítico}} \times \text{EP}(\bar{x}), \quad \boxed{IC = [\bar{x} - \text{margem}; \bar{x} + \text{margem}]}$$

O símbolo $\pm$ é uma abreviação: faça uma conta subtraindo a margem e outra somando. O **valor crítico** é um multiplicador fornecido pela tabela ou pelo enunciado; não é necessário decorá-lo.

Para escolher a coluna da tabela, usamos $n - 1$ **graus de liberdade**. Nesta etapa, basta fazer a conta: com quatro observações, $4 - 1 = 3$. O nome está ligado à informação disponível depois de calcular a média. Na tabela, $t_{0,975;3}$ indica o crítico do intervalo bilateral de 95% com três graus de liberdade.²

Para esse intervalo ser exato em amostras pequenas, as observações devem ser independentes, vir da mesma população e seguir uma distribuição normal: uma distribuição simétrica, com formato de sino. Se isso não for plausível, é preciso avaliar outro procedimento ou uma aproximação adequada; aumentar a amostra não resolve todo problema. A fórmula e sua interpretação também são apresentadas pelo NIST [10].

²A distribuição normal, a distribuição t , o significado de 0,975 e a fórmula geral do intervalo estão no Apêndice B, seção B.3.

Graus de liberdade ν	2	3	4	7	9	15	24
$t_{0,975,\nu}$	4,303	3,182	2,776	2,365	2,262	2,131	2,064

Exemplo resolvido: quatro prazos de recebimento

Para 8, 10, 10, 12 dias, $n = 4$, $\bar{x} = 10$, $s^2 = 8/3$ e $EP = s/2 \approx 0,8165$ dia. **Supondo** observações independentes de uma mesma população normal, o IC de 95% é

$$10 \pm 3,182(0,8165) = 10 \pm 2,598 \implies [7,402; 12,598] \text{ dias.}$$

Quatro observações são usadas aqui para ensinar o cálculo; não bastam para demonstrar que a normalidade seja plausível em uma aplicação real.

Exemplo resolvido: uma amostra maior

Com $n = 25$, $\bar{x} = 100$ e $s = 10$ unidades monetárias, $EP = 2$. Usando $t_{0,975,24} = 2,064$, temos $100 \pm 4,128$, isto é, $[95,872; 104,128]$. Aumentar a confiança para 99%, com a mesma amostra, exige um valor crítico maior e amplia o intervalo.

O que significa 95% de confiança?

Em repetições do mesmo procedimento amostral, aproximadamente 95% dos intervalos construídos dessa maneira conteriam a média fixa da população, sob os pressupostos. O intervalo já calculado contém ou não contém μ : não atribuímos a ele probabilidade frequentista de 95% de conter μ . Também não afirmamos que 95% dos prazos individuais estejam dentro dele.

Exercícios à mão

1. Para $n = 16$, $\bar{x} = 12$ e $s = 4$ dias, calcule o erro-padrão e um IC de 95%, usando $t_{0,975,15} = 2,131$ e os pressupostos do modelo.
2. Uma análise apresenta média 50, erro-padrão 1 e valor crítico 1,96. Calcule os dois limites do intervalo de confiança.
3. Um relatório diz: “O IC da média é $[8; 12]$, logo 95% dos clientes pagam entre 8 e 12 dias”. Explique o erro. Mantidos s e o valor crítico, o que ocorre com a margem ao quadruplicar n ?

Resultados para conferência

1. $EP = 1$ dia; $[9,869; 14,131]$ dias. 2. $EP = 1$; $[48,04; 51,96]$. 3. O intervalo estima a média, não a distribuição dos prazos individuais. A margem cai à metade; na versão t , o valor crítico também muda com n .

Aplicação prática com Python

1. Calcule média, desvio-padrão amostral e erro-padrão dos quatro prazos.
2. Obtenha o valor crítico com a função `ppf`. O comando usa a distribuição t para localizar o multiplicador do intervalo de 95% [8].

3. Construa os limites e confira [7,402; 12,598] aproximadamente. Mude a confiança para 99% e descreva a mudança, sem alterar os dados.

```
import numpy as np
from scipy import stats
prazos = np.array([8, 10, 10, 12], dtype=float)
tamanho = len(prazos)
erro_padrao = prazos.std(ddof=1) / np.sqrt(tamanho)
critico = stats.t.ppf(0.975, df=tamanho - 1)
limites = prazos.mean() + np.array([-1, 1]) * critico * erro_padrao
print(erro_padrao, critico, limites)
```

2.3 Testes de hipóteses, p-valor e decisão

Comece pela situação

Um processo foi planejado para ter prazo médio de 9 dias. Na amostra 8, 10, 10, 12, a média foi 10. Uma diferença de um dia pode surgir apenas pela seleção da amostra? O teste compara a diferença observada à escala de variação da média, sem transformar a resposta em certeza.

Conceitos e generalização

A **hipótese nula**, escrita H_0 , é o ponto de partida. Neste caso: “a média é 9 dias”. A **hipótese alternativa**, H_1 , afirma que ela é diferente. O teste é **bilateral** porque aceita diferenças para mais ou para menos. Escrevemos essas frases assim: $H_0 : \mu = 9$ e $H_1 : \mu \neq 9$.

Para medir o tamanho da diferença em relação à incerteza, calculamos:

$$t = \frac{\text{média da amostra} - \text{média de referência}}{\text{erro-padrão da média}} \quad \text{ou} \quad t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}.$$

Por exemplo, $t = 2$ significa uma diferença de dois erros-padrão. No teste bilateral, compare o tamanho de t **sem o sinal** com o valor crítico fornecido. Se alcançar ou ultrapassar esse crítico, rejeite H_0 ; se não, a evidência é insuficiente para rejeitá-la.

O programa também pode fornecer um **p-valor**. Suponha que H_0 seja verdadeira e as condições do teste estejam atendidas: o p-valor mede a chance de obter um resultado tão distante da referência quanto o observado, ou ainda mais distante. Um p-valor pequeno sinaliza menor compatibilidade dos dados com essa hipótese. Não é a probabilidade de H_0 ser verdadeira.³

Escolha antes da análise o **nível de significância**, representado por α (“alfa”). Com $\alpha = 0,05$, rejeite H_0 se $p \leq 0,05$. Caso contrário, **não rejeite**; isso não prova que a hipótese seja verdadeira. Essa regra e a comparação com o valor crítico levam à mesma decisão quando se usa o mesmo teste.

Podemos errar de duas formas: concluir que houve mudança quando não houve (**erro tipo I**) ou deixar de perceber uma mudança real (**erro tipo II**). Sob um procedimento válido, α controla o risco do primeiro erro. Mesmo um resultado estatisticamente significativo pode ter pouca importância prática: avalie também o tamanho da diferença em dias ou reais.

³A fórmula do p-valor, os testes unilaterais e o poder do teste estão no Apêndice B, seção B.4.

Exemplo resolvido: um dia de diferença

Para os quatro prazos e $H_0 : \mu = 9$ contra $H_1 : \mu \neq 9$:

$$t_{\text{obs}} = \frac{10 - 9}{0,8165} \approx 1,225.$$

Como $1,225 < 3,182$, não rejeitamos H_0 a 5%. O p-valor, calculado por software, é aproximadamente 0,308. O valor 9 também pertence ao IC de 95% já obtido: as decisões são coerentes para o mesmo teste bilateral e modelo. A evidência é insuficiente para distinguir a média de 9 dias, não para declarar igualdade exata.

Exemplo resolvido: proximidade do limiar não é certeza

Para $n = 25$, $\bar{x} = 104$, $s = 10$ e $H_0 : \mu = 100$, $t = 4/2 = 2$. Com 24 graus de liberdade, $p \approx 0,0569$ e o crítico bilateral de 5% é 2,064. Não rejeitamos a 5%. A diferença estimada continua sendo 4 unidades; deve ser relatada com incerteza, não descartada por ficar de um lado do limiar.

Exercícios à mão

1. Para $H_0 : \mu = 20$, $H_1 : \mu \neq 20$, $n = 16$, $\bar{x} = 22$ e $s = 4$, calcule t e decida a 5%. Use crítico 2,131.
2. Um teste válido produziu $p = 0,03$. Qual a decisão a 5%? E a 1%? Isso significa que H_0 tem 3% de chance de ser verdadeira?
3. Para $n = 9$, $\bar{x} = 5$, $s = 3$ e $H_0 : \mu = 5$, calcule t e o p-valor bilateral sem tabela. Descreva os erros tipo I e II para a pergunta “o prazo médio mudou em relação a 5 dias?”.

Resultados para conferência

1. EP = 1, $t = 2$; não rejeitar a 5%. 2. Rejeitar a 5%, não rejeitar a 1%; não. 3. $t = 0$, $p = 1$. Tipo I: concluir que mudou quando a média é 5; tipo II: não detectar uma mudança quando a média difere de 5.

Aplicação prática com Python

1. Declare a hipótese e $\alpha = 0,05$ antes do cálculo.
2. Reproduza t e deixe o comando `sf` calcular a probabilidade necessária ao p-valor. O fator 2 considera diferenças nas duas direções.
3. Confira com `ttest_1samp` e redija uma conclusão com média, diferença, p-valor, decisão e ressalva sobre os pressupostos.

```
import numpy as np
from scipy import stats
prazos = np.array([8, 10, 10, 12], dtype=float)
referencia = 9
erro_padrao = prazos.std(ddof=1) / np.sqrt(len(prazos))
estatistica = (prazos.mean() - referencia) / erro_padrao
pvalor = 2 * stats.t.sf(abs(estatistica), df=len(prazos) - 1)
print(estatistica, pvalor)
print(stats.ttest_1samp(prazos, popmean=referencia))
```

Checagem rápida do Módulo 2

1. Qual é a diferença entre parâmetro e estatística?
2. Por que o erro-padrão tende a diminuir quando n aumenta?
3. Como se interpreta corretamente um intervalo de confiança de 95%?
4. O que o cálculo do p-valor pressupõe sobre H_0 ?
5. Um p-valor igual a 0,30 prova ausência de efeito?
6. Qual estrutura geral conecta o teste de uma média ao teste de um coeficiente de regressão?

Síntese pessoal. Anote um erro de interpretação do p-valor que você agora consegue evitar.

Capítulo 3

Regressão simples: estimação e interpretação

Objetivo do módulo

Construir uma reta a partir dos dados e distinguir modelo populacional, reta estimada, valor observado, valor ajustado e previsão.

3.1 Como uma reta ajuda a descrever os dados

Comece pela situação

Cinco estudantes informaram horas de estudo para uma atividade e suas notas, em escala de 0 a 10. Mais horas parecem acompanhar notas maiores, mas os pares não estão perfeitamente alinhados. Por exemplo, o estudante com quatro horas obteve nota menor que o estudante com três horas.

Estudante	A	B	C	D	E
Horas de estudo x	1	2	3	4	5
Nota y	2	4	5	4	5

Revisão da reta e generalização

Uma reta descreve uma tendência média; não precisa passar por todos os pontos. Vamos chamar as horas de x e a nota de y . A nota é a **resposta** que queremos estudar; as horas são a variável **explicativa** usada para ajudar nessa descrição.

Uma equação como $\hat{y} = 2 + 0,5x$ diz: comece em 2 e acrescente 0,5 para cada hora. O símbolo $\hat{y}$ (“y chapéu”) indica a nota calculada pela reta, e não a nota realmente observada. Na notação usual:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

- $\hat{\beta}_0$ (“beta zero estimado”) é o **intercepto**: o valor da reta quando $x = 0$.
- $\hat{\beta}_1$ (“beta um estimado”) é a **inclinação**: quanto a resposta ajustada muda quando x aumenta uma unidade.

Na população, esses coeficientes são desconhecidos e recebem os mesmos nomes sem o chapéu. As diferenças individuais que a reta não explica são chamadas de erros do modelo.¹

Não confunda tendência com garantia. Mesmo com a mesma quantidade de horas, dois alunos podem obter notas diferentes. Também não interprete o intercepto automaticamente: se ninguém foi observado com zero hora, a conta nesse ponto já vai além dos dados. Uma associação, por si só, não prova causa.

Exemplo resolvido: interpretar uma reta proposta

Considere a reta ilustrativa $\hat{y} = 2 + 0,5x$, ainda não estimada por MQO. Para $x = 2$, a nota ajustada seria 3; para $x = 4$, seria 4. A diferença é $0,5(4 - 2) = 1$ ponto. A inclinação mede pontos por hora, e o intercepto é a nota ajustada em zero hora. Não é uma garantia sobre a nota individual nem uma demonstração do efeito de impor mais estudo.

Exemplo resolvido: uma aplicação contábil

Se $\hat{c} = 20 + 3q$ representa custo mensal em milhares de reais e produção em centenas de unidades, passar de $q = 4$ para $q = 5$ eleva o custo ajustado de 32 para 35 mil reais. A inclinação equivale a R\$ 3 000 por centena, ou R\$ 30 por unidade. Interpretar o intercepto como custo fixo exige que essa extrapolação e o modelo façam sentido econômico.

Exercícios à mão

1. Na relação entre receita e gasto com publicidade, com receita como resposta, identifique X e Y . Se ambos estão em milhares de reais, qual a unidade de β_1 ?
2. Para $\hat{y} = 5 + 2x$, calcule as respostas ajustadas em $x = 1$ e $x = 4$, e a diferença entre elas.
3. Um estudo observa apenas empresas com ativos entre 10 e 80 milhões. Explique por que interpretar o intercepto como lucro de uma empresa sem ativos pode ser inadequado e por que a inclinação não é automaticamente causal.

Resultados para conferência

1. X : gasto com publicidade; Y : receita. Milhares de reais de receita por mil reais de publicidade. 2. 7 e 13; diferença 6. 3. Zero está fora da faixa observada e pode não representar empresa comparável; fatores omitidos e causalidade reversa impedem a leitura causal automática.

Aplicação prática com Python

1. Desenhe os pares de horas e notas, sem ajustar um modelo ainda.
2. Sobreponha a reta proposta $2 + 0,5x$ e identifique quais pontos ficam acima e abaixo dela.
3. Altere o intercepto e depois a inclinação, separadamente. Descreva translação vertical e mudança de inclinação em linguagem comum.

¹O modelo populacional, o termo de erro e a condição matemática que permite interpretar a reta como média estão no Apêndice C, seção C.1.

```
import numpy as np
import matplotlib.pyplot as plt
horas = np.array([1, 2, 3, 4, 5], dtype=float)
notas = np.array([2, 4, 5, 4, 5], dtype=float)
plt.scatter(horas, notas, label="Observacoes")
plt.plot(horas, 2 + 0.5 * horas, label="Reta proposta")
plt.xlabel("Horas de estudo")
plt.ylabel("Nota (0 a 10)")
plt.legend()
plt.show()
```

3.2 Mínimos quadrados ordinários: cálculo da reta

Comece pela situação

Entre tantas retas possíveis, queremos uma regra que use todos os pontos. Os desvios podem ser positivos ou negativos; somá-los permitiria cancelamentos. MQO escolhe os coeficientes que minimizam a soma dos quadrados dos desvios verticais. Desvios maiores recebem maior peso nessa soma.

Conceitos e generalização

O nome **mínimos quadrados ordinários (MQO)** descreve a escolha: calcular os desvios entre notas observadas e notas da reta, elevar cada desvio ao quadrado e procurar a reta com a menor soma. Para obter seus coeficientes, usamos duas contas:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

1. Calcule as médias de x e y .
2. Para cada linha, subtraia essas médias dos respectivos valores.
3. Some os quadrados dos desvios de x : esse total é S_{xx} .
4. Some os produtos dos desvios de x e y : esse total é S_{xy} .
5. Divida S_{xy} por S_{xx} para obter a inclinação. Depois, subtraia da média de y o produto da inclinação pela média de x .

Precisamos de valores diferentes de x para ter $S_{xx} > 0$ e conseguir fazer a divisão. A reta passa pelo par de médias $(\bar{x}, \bar{y})$, o que ajuda a conferir a conta.²

²Para entender por que essas fórmulas minimizam a soma dos quadrados, consulte o Apêndice C, seção C.2. A demonstração usa derivadas e é opcional.

Exemplo resolvido: horas e notas, passo a passo

x_i	y_i	$x_i - 3$	$y_i - 4$	$(x_i - 3)^2$	$(x_i - 3)(y_i - 4)$
1	2	-2	-2	4	4
2	4	-1	0	1	0
3	5	0	1	0	0
4	4	1	0	1	0
5	5	2	1	4	2
15	20	0	0	10	6

As médias são $\bar{x} = 3$ e $\bar{y} = 4$, com $S_{xx} = 10$ e $S_{xy} = 6$. Logo,

$$\hat{\beta}_1 = 6/10 = 0,6, \quad \hat{\beta}_0 = 4 - 0,6(3) = 2,2, \quad \boxed{\hat{y} = 2,2 + 0,6x}.$$

Uma hora adicional está associada a 0,6 ponto a mais na nota média ajustada. No ponto $x = 3$, a reta fornece $\hat{y} = 4 = \bar{y}$.

Exemplo resolvido: ativo explicando lucro

No caso das oito empresas, $S_{xy} = 390$ e $S_{xx} = 4200$. Portanto, $\hat{\beta}_1 = 13/140 \approx 0,09286$ e $\hat{\beta}_0 = 4,5 - (13/140)45 = 9/28 \approx 0,32143$. Cada R\$ 1 milhão adicional de ativo está associado a cerca de R\$ 0,09286 milhão de lucro ajustado, dentro da relação descrita. Para ativo de R\$ 50 milhões, $\hat{y} \approx 4,9643$ milhões.

Exercícios à mão

1. Para $\bar{x} = 2$, $\bar{y} = 5$, $S_{xx} = 4$ e $S_{xy} = 8$, encontre a reta MQO e o valor ajustado em $x = 3$.
2. Para $x = (1, 2, 3)$ e $y = (2, 3, 5)$, calcule médias, S_{xx} , S_{xy} e os dois coeficientes. Confira a passagem pelas médias.
3. Uma reta em reais é $\hat{y} = 100 + 20x$, com x em unidades físicas. Reescreva-a com y em milhares de reais e calcule o valor ajustado em $x = 3$ nas duas unidades. A mudança de unidade muda o custo representado?

Resultados para conferência

1. $\hat{y} = 1 + 2x$; $\hat{y}(3) = 7$. 2. $\bar{x} = 2$, $\bar{y} = 10/3$, $S_{xx} = 2$, $S_{xy} = 3$; $\hat{\beta}_1 = 1,5$, $\hat{\beta}_0 = 1/3$; $\hat{y}(2) = 10/3$. 3. $\widehat{y_{\text{mil}}} = 0,1 + 0,02x$. Em $x = 3$, R\$ 160 ou R\$ 0,160 mil. O custo é o mesmo.

Aplicação prática com Python

1. Reproduza as somas S_{xx} e S_{xy} com NumPy, antes de usar um comando que calcule a reta automaticamente.
2. Calcule a inclinação e o intercepto; confira 0,6 e 2,2.
3. Compare com `scipy.stats.linregress`, que estima a regressão simples por mínimos quadrados [9]. Interprete as unidades dos coeficientes.

```
import numpy as np
from scipy import stats
horas = np.array([1, 2, 3, 4, 5], dtype=float)
notas = np.array([2, 4, 5, 4, 5], dtype=float)
soma_xx = ((horas - horas.mean()) ** 2).sum()
soma_xy = ((horas - horas.mean()) * (notas - notas.mean())).sum()
inclinacao = soma_xy / soma_xx
intercepto = notas.mean() - inclinacao * horas.mean()
print(soma_xx, soma_xy, intercepto, inclinacao)
ajuste = stats.linregress(horas, notas)
print(ajuste.intercept, ajuste.slope)
```

3.3 Valores ajustados, resíduos e previsão pontual

Comece pela situação

Para o estudante com uma hora de estudo, a reta prevê 2,8, mas a nota observada é 2. A diferença $-0,8$ é informação sobre o quanto a reta errou nesse ponto. Não devemos substituir a nota observada pela ajustada ao descrever os dados originais.

Conceitos e generalização

Para cada observação da amostra:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i, \quad e_i = y_i - \hat{y}_i, \quad y_i = \hat{y}_i + e_i.$$

Calcule sempre **observado menos ajustado**. Resíduo positivo significa que o ponto ficou acima da reta; negativo, abaixo. O resíduo usa a reta da amostra. Ele não é o mesmo que o erro da verdadeira relação populacional, que não conhecemos.

Em MQO com intercepto, os resíduos somam zero, salvo arredondamentos. Essa é uma característica da conta; não demonstra que o modelo esteja completo ou que não haja problemas nos dados.³


Para um novo valor x_0 , a previsão pontual é $\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$. Ela estima a média da resposta para aquele valor de x e também é usada para prever uma nova observação. As incertezas são diferentes, como veremos no Módulo 4. Prever dentro da faixa observada é **interpolar**; fora dela é **extrapolar**. Mesmo uma interpolação exige contexto comparável.

Exemplo resolvido: tabela completa do ajuste

x_i	y_i	$\hat{y}_i = 2,2 + 0,6x_i$	e_i	e_i^2
1	2	2,8	-0,8	0,64
2	4	3,4	0,6	0,36
3	5	4,0	1,0	1,00
4	4	4,6	-0,6	0,36
5	5	5,2	-0,2	0,04
15	20	20,0	0,0	2,40

³As propriedades matemáticas dos resíduos estão no Apêndice C, seção C.2.

Para conferir, some a coluna dos resíduos: o resultado é zero. Para a reta proposta no tópico anterior, $2 + 0,5x$, a soma dos resíduos quadráticos seria 3,75, maior que os 2,40 de MQO.



As linhas verticais representam os resíduos, cuja distância foi minimizada em quadrados; não são distâncias perpendiculares à reta.

Exemplo resolvido: prever não é garantir

Para $x_0 = 4$, a previsão é 4,6 pontos, dentro da faixa de uma a cinco horas. Para $x_0 = 6$, a fórmula fornece 5,8, mas já é extrapolação. Para $x_0 = 20$, fornece 14,2, acima do máximo da escala: a reta não deve ser estendida indiscriminadamente.

Exercícios à mão

1. Para $\hat{y} = 1 + 2x$, com $x = 3$ e $y = 8$, calcule o valor ajustado e o resíduo. O ponto está acima ou abaixo da reta?
2. Para o ajuste de $x = (1, 2, 3)$ e $y = (2, 3, 5)$ do tópico anterior, obtenha os três valores ajustados, os resíduos e sua soma de quadrados.
3. Na reta das horas e notas, calcule a previsão para 2,5 horas e para 8 horas. Classifique cada previsão e explique por que resíduos de média zero não demonstram que a reta explique todos os fatores ligados à nota.

Resultados para conferência

1. $\hat{y} = 7$, $e = 1$; acima. 2. $11/6, 10/3, 29/6$; resíduos $1/6, -1/3, 1/6$; soma zero e soma dos quadrados $1/6$. 3. 3,7 (interpolação) e 7 (extrapolação). A média residual zero é produzida pela própria conta de MQO com intercepto. Ela não descarta, por exemplo, diferenças de preparação anterior entre os estudantes.

Aplicação prática com Python

1. Ajuste a reta e construa uma tabela com observado, ajustado e resíduo.
2. Confira soma dos resíduos próxima de zero e soma dos quadrados 2,4. Erros numéricos minúsculos decorrem da aritmética de ponto flutuante.
3. Calcule as previsões em 4 e 6 horas e acrescente à interpretação a ressalva sobre extrapolação, que o software não decide por você.

```
import numpy as np
import pandas as pd
from scipy import stats
horas = np.array([1, 2, 3, 4, 5], dtype=float)
notas = np.array([2, 4, 5, 4, 5], dtype=float)
ajuste = stats.linregress(horas, notas)
ajustados = ajuste.intercept + ajuste.slope * horas
residuos = notas - ajustados
print(pd.DataFrame({"horas": horas, "notas": notas,
                    "ajustado": ajustados, "residuo": residuos}))
print(residuos.sum(), (residuos ** 2).sum())
print(ajuste.intercept + ajuste.slope * np.array([4, 6]))
```

Checagem rápida do Módulo 3

1. Qual é a diferença entre ε_i e e_i ?
2. O que o método de mínimos quadrados ordinários minimiza?
3. Por que somar apenas os resíduos não produz um bom critério de ajuste?
4. Como interpretar $\hat{\beta}_1 = 0,9$ em um exemplo com unidades definidas?
5. Por que o intercepto pode não ter interpretação substantiva?
6. O que acontece com a inclinação quando a unidade de X muda de reais para milhares de reais?

Síntese pessoal. Explique o coeficiente angular com as unidades de X e Y , sem usar a palavra “causa”.

Capítulo 4

Regressão simples: inferência e avaliação

Objetivo do módulo

Separar qualidade do ajuste, precisão dos coeficientes e validade das conclusões. Uma reta pode resumir os dados sem sustentar uma interpretação causal ou uma previsão confiável fora da amostra.

4.1 Decomposição da variabilidade, R^2 e erro residual

Comece pela situação

Sem usar as horas de estudo, preveríamos a nota média 4 para todos. Usando a reta $2,2 + 0,6x$, a soma dos erros quadráticos diminui. Quanto da variação em torno da média a reta consegue representar?

Conceitos e generalização

Compare duas formas de prever: usar a média para todos ou usar a reta. Para cada forma, somamos os desvios ao quadrado. Assim, não deixamos diferenças positivas e negativas se anularem. No ajuste MQO com intercepto:

$$SQ_T = \sum (y_i - \bar{y})^2, \quad SQ_{\text{Reg}} = \sum (\hat{y}_i - \bar{y})^2, \quad SQ_{\text{Res}} = \sum (y_i - \hat{y}_i)^2.$$

Leia SQ_T como a variação total em torno da média, SQ_{Reg} como a parte representada pela reta e SQ_{Res} como a parte que ficou nos resíduos. Essas partes se relacionam assim:

$$SQ_T = SQ_{\text{Reg}} + SQ_{\text{Res}}, \quad R^2 = \frac{SQ_{\text{Reg}}}{SQ_T} = 1 - \frac{SQ_{\text{Res}}}{SQ_T}.$$

Para obter R^2 , divida a parte residual pelo total e subtraia de 1. Se a resposta varia, o resultado fica entre 0 e 1 nesse tipo de ajuste. Multiplique por 100 para escrever em porcentagem. Na regressão simples com intercepto, também podemos obter R^2 elevando a correlação ao quadrado.¹

¹A demonstração da decomposição e as condições para $R^2 = r^2$ estão no Apêndice C, seção C.3.

Estimando dois coeficientes, restam $n - 2$ graus de liberdade residuais:

$$s_e^2 = \frac{SQ_{\text{Res}}}{n - 2}, \quad s_e = \sqrt{\frac{SQ_{\text{Res}}}{n - 2}}, \quad n > 2.$$

Faça, portanto, duas contas: divida a soma residual por $n - 2$ e tire a raiz. O desconto de 2 se deve aos dois coeficientes calculados, intercepto e inclinação. O desvio-padrão residual s_e mede a dispersão que resta em torno da reta, na unidade de y . Já s_y descreve a dispersão dos valores em torno da média, antes de usar a reta.

Exemplo resolvido: decomposição nas horas e notas

Os desvios das notas em relação a 4 são $-2, 0, 1, 0, 1$, logo $SQ_T = 6$. Os desvios dos valores ajustados são $-1, 2, -0, 6, 0, 0, 6, 1, 2$, logo $SQ_{\text{Reg}} = 3, 6$. Já sabemos que $SQ_{\text{Res}} = 2, 4$.

$$6 = 3, 6 + 2, 4, \quad R^2 = 1 - 2, 4/6 = 0, 60, \quad s_e^2 = 2, 4/3 = 0, 8, \quad s_e \approx 0, 8944.$$

A reta representa 60% da variabilidade amostral das notas em torno da média. Isso não significa que explique causalmente 60% das notas ou que acerte 60% de cada nota individual.

Fonte	Soma de quadrados	Graus de liberdade	Quadrado médio
Regressão	3,6	1	3,6
Resíduos	2,4	3	0,8
Total	6,0	4	—

Exemplo resolvido: comparar escalas

Se as notas forem multiplicadas por 10, todas as somas de quadrados serão multiplicadas por 100. O R^2 continuará 0,60, mas s_e passará a aproximadamente 8,944. A escala muda o erro em unidades originais, mas não a fração da variação representada pelo ajuste.

Exercícios à mão

1. Se $SQ_T = 50$ e $SQ_{\text{Res}} = 20$, calcule SQ_{Reg} e R^2 .
2. Para $n = 6$ e $SQ_{\text{Res}} = 16$, obtenha graus de liberdade, s_e^2 e s_e .
3. Se $r = -0,8$, qual é o R^2 da regressão simples com intercepto? É possível descobrir o sinal da inclinação a partir apenas de R^2 ? Um R^2 alto garante ausência de padrão nos resíduos?

Resultados para conferência

1. 30 e 0,60. 2. 4; 4; 2. 3. 0,64; não, o quadrado elimina o sinal; não, é necessário inspecionar os resíduos e a adequação do modelo.

Aplicação prática com Python

1. Ajuste o caso das notas e calcule separadamente as três somas de quadrados.
2. Verifique a identidade e obtenha R^2 e s_e .

3. Compare R^2 ao quadrado de `rvalue`. Escreva a interpretação sem empregar a palavra “causa”.

```
import numpy as np
from scipy import stats
horas = np.array([1, 2, 3, 4, 5], dtype=float)
notas = np.array([2, 4, 5, 4, 5], dtype=float)
ajuste = stats.linregress(horas, notas)
ajustados = ajuste.intercept + ajuste.slope * horas
sq_total = ((notas - notas.mean()) ** 2).sum()
sq_regressao = ((ajustados - notas.mean()) ** 2).sum()
sq_residuos = ((notas - ajustados) ** 2).sum()
r_quadrado = 1 - sq_residuos / sq_total
desvio_residual = np.sqrt(sq_residuos / (len(horas) - 2))
print(sq_total, sq_regressao, sq_residuos)
print(r_quadrado, ajuste.rvalue ** 2, desvio_residual)
```

4.2 Erros-padrão, teste t e intervalos dos coeficientes

Comece pela situação

A inclinação estimada foi 0,6 ponto por hora, mas temos apenas cinco estudantes. Outras amostras produziram outras inclinações. O erro-padrão mede essa incerteza: um coeficiente positivo na amostra pode ser compatível com uma inclinação populacional nula.

Conceitos e generalização

A ideia é a mesma do teste de uma média: comparar o número estimado com um valor de referência, levando em conta a incerteza. Aqui, o número é a inclinação da reta. O valor zero representa ausência de tendência linear na média da resposta.

Para usar os cálculos usuais, precisamos de algumas condições, chamadas **pressupostos**: a reta deve descrever adequadamente a média; os erros devem ter média zero em cada valor de x , dispersão constante e não apresentar correlação entre observações. Para a inferência exata com amostras pequenas, assumimos também erros independentes e com distribuição normal, para os valores de x considerados. Essas condições serão discutidas no diagnóstico; o simples fato de o programa produzir uma reta não as confirma.²

O erro-padrão da inclinação pode ser fornecido pelo programa ou calculado dividindo o desvio-padrão residual pela raiz de S_{xx} :

$$EP(\hat{\beta}_1) = \frac{s_e}{\sqrt{S_{xx}}}.$$

Depois, use o mesmo roteiro do capítulo anterior:

$$t = \frac{\text{inclinação estimada} - \text{inclinação de referência}}{\text{erro-padrão da inclinação}},$$

$$IC = \text{inclinação estimada} \pm t_{\text{crítico}} \times \text{erro-padrão da inclinação}.$$

Para testar inclinação zero, o numerador é apenas a inclinação estimada. Compare o tamanho de t , sem o sinal, com o crítico. Na regressão simples com intercepto, use $n - 2$ graus de liberdade: descontamos os dois coeficientes.

²As condições em notação matemática e os erros-padrão dos dois coeficientes estão no Apêndice C, seção C.4.

Exemplo resolvido: inferência da inclinação

No caso das notas, $s_e^2 = 0,8$, $S_{xx} = 10$ e $n - 2 = 3$:

$$EP(\hat{\beta}_1) = \sqrt{0,8/10} = \sqrt{0,08} \approx 0,28284.$$

Para $H_0 : \beta_1 = 0$, $t \approx 0,6/0,28284 = 2,1213$. Como o crítico de 5% é 3,182, não rejeitamos H_0 ; $p \approx 0,1240$. O IC de 95% é

$$0,6 \pm 3,182(0,28284) \approx [-0,300; 1,500].$$

Apesar de $R^2 = 0,60$, a amostra é pequena e o intervalo é amplo. Não rejeitar a inclinação nula não prova que estudar seja irrelevante.

Exemplo resolvido: a mesma estimativa, incertezas diferentes

Dois estudos estimam uma inclinação de 1. No primeiro, o erro-padrão é 0,5; no segundo, 0,25. Para testar inclinação zero, as estatísticas são $1/0,5 = 2$ e $1/0,25 = 4$. Com o mesmo valor crítico, o segundo estudo traz evidência mais forte contra a inclinação zero. O tamanho da estimativa, sozinho, não conta toda a história.

Exercícios à mão

1. Com $s_e = 2$ e $S_{xx} = 16$, calcule $EP(\hat{\beta}_1)$. Se $\hat{\beta}_1 = 1,5$, qual o t para testar inclinação zero?
2. Para $n = 6$, $\hat{\beta}_1 = 2$, $EP(\hat{\beta}_1) = 0,5$, construa um IC de 95% e decida o teste bilateral da inclinação nula. Use $t_{0,975,4} = 2,776$.
3. Se S_{xx} quadruplicar e s_e permanecer igual, o que acontece com o erro-padrão da inclinação? Explique por que um p-valor pequeno não garante que nenhum fator importante tenha ficado fora da análise.

Resultados para conferência

1. 0,5; $t = 3$. 2. $[0,612; 3,388]$; $t = 4 > 2,776$, rejeitar a 5%. 3. Cai à metade. O p-valor depende das condições do modelo; não mostra, por si só, se foram considerados os fatores necessários para explicar a relação.

Aplicação prática com Python

1. Estime o modelo e consulte o erro-padrão da inclinação.
2. Obtenha o crítico com $n - 2$ graus de liberdade, e não $n - 1$.
3. Construa o intervalo da inclinação e confira $[-0,300; 1,500]$. Relate o p-valor juntamente com a estimativa e o intervalo, não sozinho.

```
import numpy as np
from scipy import stats
horas = np.array([1, 2, 3, 4, 5], dtype=float)
notas = np.array([2, 4, 5, 4, 5], dtype=float)
ajuste = stats.linregress(horas, notas)
critico = stats.t.ppf(0.975, df=len(horas) - 2)
intervalo = ajuste.slope + np.array([-1, 1]) * critico * ajuste.stderr
print(ajuste.stderr)
print(ajuste.slope / ajuste.stderr, ajuste.pvalue, intervalo)
```

4.3 Intervalo da média e intervalo de previsão

Comece pela situação

Qual é a nota média de estudantes com três horas de estudo? E qual será a nota de um estudante específico com três horas? A segunda pergunta acrescenta a variação individual em torno da média, por isso exige um intervalo mais largo.

Conceitos e generalização

Há duas perguntas diferentes:

- **Média de um grupo:** qual a nota média de estudantes que estudaram três horas? Usamos um intervalo de confiança para essa média.
- **Uma pessoa:** qual a nota de um novo estudante que estudou três horas? Usamos um intervalo de previsão, que considera também diferenças individuais.

A previsão pontual é a mesma, mas o segundo intervalo é mais largo. O programa calcula um erro-padrão para cada pergunta. Com esses números fornecidos, a conta continua simples:

$$\text{limites} = \text{previsão pontual} \pm t_{\text{crítico}} \times \text{erro-padrão adequado.}$$

Não troque os dois erros-padrão. A fórmula completa para obtê-los é um aprofundamento, não um requisito para interpretar os intervalos.³ Os intervalos dependem das condições do modelo discutidas antes. Para prever um novo caso, ele deve ser independente dos anteriores e vir do mesmo processo.

Exemplo resolvido: três horas de estudo

Para três horas, a reta fornece $\hat{y} = 2,2 + 0,6(3) = 4$. Os erros-padrão calculados pelo modelo são 0,4 para a média e aproximadamente 0,9798 para um novo estudante. Use o crítico 3,182446. A margem do primeiro intervalo é $3,182446 \times 0,4 \approx 1,273$; a do segundo é aproximadamente 3,118. Assim:

$$IC_{95\%} \approx [2,727; 5,273], \quad IP_{95\%} \approx [0,882; 7,118].$$

O primeiro intervalo se refere à média das notas para três horas; o segundo, à nota de um novo estudante, sob as hipóteses adotadas.

³Para calcular os erros-padrão da média prevista e de uma nova observação, consulte o Apêndice C, seção C.5.

Exemplo resolvido: afastar-se do centro

Em quatro horas, a previsão é 4,6. O IC de 95% é aproximadamente [3,041; 6,159] e o IP, [1,355; 7,845]. Ambos ficam mais largos do que no centro. As fórmulas também geram números fora da faixa de X , mas não protegem contra mudança da relação fora dessa faixa.

Exercícios à mão

1. Um relatório fornece dois intervalos para o mesmo número de horas: [3; 5] para a média de um grupo e [1; 7] para um novo estudante. Qual é mais largo? Por que eles respondem a perguntas diferentes?
2. Para um custo em R\$ milhares, suponha $\hat{y}_0 = 10$, $EP_{\text{média}} = 1$, $EP_{\text{prev}} = 2$ e crítico $t = 4,303$. Construa o IC e o IP de 95%.
3. Por que usar o erro-padrão da média para prever uma pessoa gera um intervalo estreito demais? Um intervalo muito estreito em extrapolação garante confiabilidade?

Resultados para conferência

1. O segundo: largura 6, contra 2 do primeiro. Ele considera também as diferenças individuais em torno da média. 2. IC [5,697; 14,303]; IP [1,394; 18,606]. 3. Ignora a variação individual em torno da média e subestima a incerteza. Não: os intervalos dependem da validade do modelo no novo contexto.

Aplicação prática com Python

1. Use os erros-padrão fornecidos para três horas: 0,4 e 0,9798.
2. Calcule os dois intervalos e compare suas larguras.
3. Explique qual intervalo responde à pergunta sobre um novo estudante. O código completo para calcular os erros-padrão está no Apêndice C.

```
import numpy as np
previsao = 4
erro_medio = 0.4
erro_individual = 0.9798
critico = 3.182446
sentidos = np.array([-1, 1])
print(previsao + sentidos * critico * erro_medio)
print(previsao + sentidos * critico * erro_individual)
```

4.4 Pressupostos, diagnóstico e observações influentes

Comece pela situação

Uma reta pode ter R^2 elevado e deixar resíduos em forma de curva. Pode também depender fortemente de uma única empresa. Antes de aceitar o resultado, precisamos observar o que o ajuste não captou. O diagnóstico gráfico complementa, e não é substituído pelo R^2 [11].

Conceitos e generalização

Condição	Sinal ou investigação	Consequência e encaminhamento
Uma reta representa bem a média	Resíduos formam uma curva.	Uma relação curva pode precisar de outro modelo.
Não há erro médio sistemático em cada valor de x	Investigar fatores importantes que ficaram de fora e erros de registro.	Um bom ajuste não descarta essas distorções.
Dispersão dos erros aproximadamente constante	Resíduos se abrem como um leque.	Rever os erros-padrão antes de confiar nos testes e intervalos.
Erros sem relação entre observações	Longas sequências do mesmo sinal por data.	Verificar se dados próximos no tempo dependem uns dos outros.
Erros com distribuição normal, para inferência exata em amostra pequena	Avaliar se há desvios muito extremos e se a hipótese é plausível.	Calcular a reta é possível sem essa hipótese; confiar na inferência requer cuidado.
O resultado não depende excessivamente de um único ponto	A reta muda muito quando se retira uma observação.	Conferir o registro e relatar a mudança, sem excluir dados automaticamente.

No gráfico de resíduos, desenhe uma linha horizontal no zero. Procure pontos distribuídos dos dois lados, sem uma curva visível e sem aumento sistemático da dispersão. Um leque sugere **heterocedasticidade**: nome técnico para a situação em que a variância dos erros não é constante. O contrário, variância constante, é chamado de **homocedasticidade**. Os termos descrevem o padrão, não uma decisão automática sobre o modelo.

Com apenas cinco observações, é difícil perceber padrões. Ausência de um problema visível não prova que todas as condições sejam satisfeitas.

Um **ponto discrepante** pode ter resposta muito longe da reta. Um ponto **influyente** é aquele cuja retirada muda bastante o ajuste. Não são necessariamente a mesma coisa. Há medidas numéricas, como alavancagem e distância de Cook, que ajudam nessa investigação.⁴

Exemplo resolvido: a primeira observação das notas

Com os cinco estudantes, a inclinação era 0,6. Sem o primeiro, que estudou uma hora e obteve nota 2, as quatro observações restantes fornecem $\hat{y} = 3,8 + 0,2x$, em vez de $2,2 + 0,6x$. A mudança de inclinação é relevante. Devemos conferir o registro, entender se a observação pertence ao universo estudado e relatar a sensibilidade; não removê-la apenas por enfraquecer ou fortalecer a hipótese desejada.

Exemplo resolvido: um sinal de alerta nos custos

Suponha que as previsões errem pouco nas empresas pequenas e muito nas grandes. Um gráfico pode mostrar o leque descrito acima. A reta ainda pode resumir uma tendência, mas os erros-padrão usuais podem não ser adequados. Não basta manter o teste antigo só porque o R^2 parece bom.

⁴As fórmulas, os exemplos completos e o gráfico Q-Q estão no Apêndice C, seção C.6. No percurso principal, o foco é reconhecer os sinais de alerta e explicar seus limites.

Exercícios à mão

1. Associe os padrões dos resíduos a problemas a investigar: curva em U; leque crescente; longas sequências de sinais iguais por data.
2. A inclinação é 0,6 com todos os dados e 0,2 sem uma observação. O que essa comparação sugere? É suficiente para excluir o ponto?
3. Um relatório afirma que o modelo é confiável porque tem $R^2 = 0,95$, mas os resíduos formam um leque. O que precisa ser revisto antes de aceitar o teste e o intervalo de confiança apresentados?

Resultados para conferência

1. Não linearidade; heterocedasticidade; dependência temporal. 2. O ponto pode ser influente. Não excluir automaticamente: conferir o registro, sua pertinência à pesquisa e a sensibilidade do resultado. 3. A hipótese de variância constante e os erros-padrão usados. Um R^2 alto não garante que a inferência esteja correta.

Aplicação prática com Python

1. Faça o gráfico de resíduos versus valores ajustados. Não conclua que todas as condições estejam confirmadas apenas porque há poucos pontos.
2. Reestime sem a primeira observação para uma análise de sensibilidade; preserve a base original e compare a inclinação 0,2 com 0,6.
3. Em uma base temporal real, acrescente resíduos versus data. Esta base de estudantes não tem ordem temporal informada.

```
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats
horas = np.array([1, 2, 3, 4, 5], dtype=float)
notas = np.array([2, 4, 5, 4, 5], dtype=float)
ajuste = stats.linregress(horas, notas)
ajustados = ajuste.intercept + ajuste.slope * horas
residuos = notas - ajustados
plt.scatter(ajustados, residuos)
plt.axhline(0, color="black", linewidth=1)
plt.xlabel("Nota ajustada")
plt.ylabel("Residuo")
plt.show()
sensibilidade = stats.linregress(horas[1:], notas[1:])
print(sensibilidade.intercept, sensibilidade.slope)
```

Síntese da unidade: como escrever o resultado

Um relatório deve informar pergunta, origem e seleção dos dados, variáveis e unidades, tamanho amostral, modelo estimado, incerteza, diagnóstico e limitações. Para o caso construído, uma redação possível é:

Modelo de relato crítico

Nos cinco pares fictícios, a reta MQO foi $\hat{y} = 2,2 + 0,6x$, com x em horas e y em pontos. O ajuste apresentou $R^2 = 0,60$ e desvio-padrão residual de 0,894 ponto. Sob o modelo clássico normal, a inclinação teve erro-padrão 0,283, IC de 95% aproximadamente $[-0,300; 1,500]$ e p-valor bilateral 0,124 para inclinação nula. Apenas cinco observações limitam a avaliação dos pressupostos, e retirar a primeira altera a inclinação para 0,2. Os resultados descrevem uma associação e não identificam o efeito causal de uma hora adicional de estudo.

Os próximos estudos ampliarão esse raciocínio para múltiplos regressores, diagnósticos formais, erros-padrão robustos e séries temporais. Nenhuma dessas extensões dispensa a definição da pergunta e a verificação da qualidade dos dados.

Checklist para avaliar uma regressão

1. O diagrama de dispersão sugere uma relação aproximadamente linear?
2. Há observações atípicas ou influentes?
3. Os resíduos se distribuem sem padrão evidente em torno de zero?
4. O tamanho do erro é aceitável no contexto da análise?
5. A inclinação tem interpretação substantiva e unidades coerentes?
6. O intervalo de confiança informa uma faixa útil para a decisão?
7. O R^2 foi interpretado como medida de ajuste, sem conclusão causal automática?
8. A previsão permanece dentro de uma faixa relevante dos dados observados?

Questão integradora

Considere o modelo estimado

$$\widehat{ROA} = 2,1 + 0,35 \text{ MargemBruta},$$

com $EP(\hat{\beta}_1) = 0,10$, p-valor igual a 0,002 e $R^2 = 0,42$. Considere ROA e margem bruta medidos em pontos percentuais.

Pergunta para pensar

Em linguagem comum, explique o coeficiente 0,35, o p-valor e o R^2 . Depois, esclareça por que nenhuma dessas informações, isoladamente, prova causalidade.

Ideia-chave

Uma análise completa separa a magnitude da associação, a incerteza da estimativa, a qualidade do ajuste e o alcance causal da conclusão.

Síntese pessoal. Resuma essas quatro dimensões no espaço abaixo.

Apêndice A

Revisão matemática e medidas descritivas

Este apêndice reúne explicações adicionais. Você pode consultar apenas a seção indicada na nota de rodapé e depois voltar ao exemplo do capítulo. As regras não substituem a pergunta prática: o que queremos saber sobre os dados?

A.1 Sinais, potências e raízes

Multiplicar dois números negativos produz um resultado positivo: $(-3)(-2) = 6$. Por isso, $(-3)^2 = (-3)(-3) = 9$. Os parênteses fazem diferença. Em $(-3)^2$, elevamos o número -3 ao quadrado: $(-3) \times (-3) = 9$. Já em -3^2 , sem parênteses, calculamos primeiro a potência $3^2 = 9$ e depois aplicamos o sinal de menos: $-3^2 = -(3^2) = -9$. Portanto, $(-3)^2$ e -3^2 têm resultados diferentes. A raiz quadrada indicada por $\sqrt{9}$ é a raiz não negativa, 3.

A.2 Somatórios

O símbolo de somatório é a letra grega sigma maiúscula:

$$\sum$$

Ele indica que devemos **somar os valores indicados**. Por exemplo, se temos $x_1 = 1$, $x_2 = 2$ e $x_3 = 4$, escrevemos:

$$\sum_{i=1}^3 x_i = x_1 + x_2 + x_3 = 1 + 2 + 4 = 7.$$

Leia: “some os valores de x_i , de $i = 1$ até $i = 3$ ”. O i indica a posição na lista; o 1 indica onde começar e o 3, onde terminar. O termo x_i , à direita do símbolo, mostra o que somar.

Diferentes formas de escrever a mesma soma

Quando a lista tem n valores, podemos encontrar estas notações:

$$\sum_{i=1}^n x_i, \quad \sum_i x_i, \quad \sum x_i.$$

A primeira mostra o início e o fim da soma. As outras são abreviações: os limites ficam subentendidos. Nesta apostila, quando eles não aparecem, somamos todos os valores da lista em estudo.

Os limites também podem aparecer acima e abaixo do símbolo, $\sum_{i=1}^n x_i$, ou ao lado, $\sum_{i=1}^n x_i$. A posição muda, mas a conta é a mesma.

Regras e cuidados ao calcular

Se a , b e c forem constantes, isto é, números que não mudam ao percorrer a lista, podemos distribuir a soma:

$$\sum_{i=1}^n c = nc, \quad \sum_{i=1}^n (a + bx_i) = na + b \sum_{i=1}^n x_i.$$

Por exemplo, com $x = (1, 2, 4)$, somar $2 + 3x_i$ é somar $5 + 8 + 14 = 27$. A mesma conta pode ser feita como $3 \cdot 2 + 3(1 + 2 + 4) = 27$.

Não confunda soma de quadrados com quadrado da soma:

$$\sum x_i^2 = 1^2 + 2^2 + 4^2 = 21, \quad (\sum x_i)^2 = (1 + 2 + 4)^2 = 49.$$

Também não se pode trocar $\sum x_i y_i$ por $(\sum x_i)(\sum y_i)$. Na primeira expressão, cada produto mantém o par observado na mesma linha.

A.3 Por que a variância amostral usa n menos um?

Depois de calcular a média, os desvios somam zero:

$$\sum (x_i - \bar{x}) = \sum x_i - n\bar{x} = 0.$$

Essa igualdade impõe uma restrição. Se três desvios somam zero e dois deles são -2 e 1 , o terceiro só pode ser 1 . Nesse sentido, há $n - 1$ desvios livres depois de estimar a média.

Uma justificativa probabilística usa observações independentes da mesma distribuição, com média μ e variância finita σ^2 :

$$E\left[\sum (X_i - \bar{X})^2\right] = (n - 1)\sigma^2.$$

A letra E representa a média teórica em repetições do processo amostral. Dividir a soma por $n - 1$ produz um estimador de variância cuja média teórica é σ^2 : dizemos que ele é **não viesado**. Isso não significa que cada amostra forneça a variância exata. Tampouco significa que sua raiz, s , seja exatamente não viesada para σ .

Se os dados forem a população completa de interesse, a tarefa é descrever a dispersão daqueles N valores, e o divisor é N . A distinção depende da pergunta, não de um limite de tamanho para a amostra.

A.4 Média ponderada e comparação relativa

Quando cada valor x_i tem um peso w_i , a média ponderada é

$$\bar{x}_w = \frac{\sum w_i x_i}{\sum w_i},$$

com pesos não negativos e soma positiva. Se três unidades custam R\$ 10 e uma custa R\$ 16, a média é $(3 \cdot 10 + 1 \cdot 16)/4 = 11,50$ reais. O peso representa a quantidade de unidades de cada preço.

O **coeficiente de variação** expressa o desvio-padrão como percentual da média: $CV = 100s/\bar{x}$. Para média 10 e desvio-padrão 2, $CV = 20\%$. Sua interpretação exige uma escala com zero significativo e média positiva, não próxima de zero. Lucros negativos ou quase nulos tornam a medida pouco útil ou enganosa para comparação.

A.5 Classes desiguais e regra do boxplot

Se f_j é a contagem da classe j , sua frequência relativa é $p_j = f_j/n$. As contagens somam n , e as frequências relativas somam 1. Com classes de larguras diferentes, as alturas do histograma devem considerar essa largura para que a **área** represente a frequência relativa:


$$\text{densidade na classe } j = \frac{p_j}{b_j - a_j}.$$

Se 25% dos valores estão em uma classe de largura 2 e 50% em uma classe de largura 4, ambas têm altura 0,125. A segunda barra tem o dobro da área, porque é duas vezes mais larga.

O **boxplot** usa mediana e quartis. Pela regra usual, valores abaixo de $Q_1 - 1,5AIQ$ ou acima de $Q_3 + 1,5AIQ$, com $AIQ = Q_3 - Q_1$, são marcados como afastados. Essa marcação pede investigação; não autoriza exclusão automática. Diferentes regras de cálculo dos quartis podem mudar o resultado em amostras pequenas.

Como ler um boxplot

Considere os prazos fictícios de pagamento, em dias, já em ordem: 2, 3, 4, 4, 5, 6, 7, 8, 8, 10, 18. A mediana é 6, o valor central. Para este exemplo, calculamos os quartis pela mediana de cada metade, sem incluir a mediana geral: $Q_1 = 4$ e $Q_3 = 8$.



- **Caixa:** vai de $Q_1 = 4$ a $Q_3 = 8$ e representa a região central dos dados. A linha dentro dela marca a mediana, 6 dias.
- **Bigodes:** vão até o menor e o maior valor observado que não ultrapassam os limites da regra: aqui, 2 e 10 dias.
- **Ponto isolado:** os 18 dias ultrapassam o limite superior. É um prazo que merece atenção, não necessariamente um erro.

Neste caso, $AIQ = 8 - 4 = 4$. Os limites são $4 - 1,5 \times 4 = -2$ e $8 + 1,5 \times 4 = 14$ dias. São limites de comparação, não prazos observados: por isso, os bigodes terminam em 2 e 10, e não em -2 e 14.

A.6 Covariância e correlação: cálculo direto

Para calcular a **covariância amostral**, multiplique os desvios de cada variável em relação a sua média e some os produtos. Depois, divida por $n - 1$:

$$s_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n - 1}.$$

Aqui, n é a quantidade de pares, e $\bar{x}$ e $\bar{y}$ são as médias. Usamos s_{xy} , com letra minúscula, para a covariância; na apostila, S_{xy} , com letra maiúscula, indica apenas a soma antes da divisão.

A **correlação** é a covariância dividida pelo produto dos desvios-padrão amostrais de x e de y :

$$r = \frac{s_{xy}}{s_x \cdot s_y}.$$

Se um dos desvios-padrão for zero, a correlação não pode ser calculada.

Exemplo resolvido: as oito empresas

Considerando os dados da Tabela 1.1, a soma dos produtos dos desvios é 390. Com $n = 8$, temos:

$$s_{xy} = \frac{390}{8 - 1} \approx 55,714, \quad r \approx \frac{55,714}{24,495 \times 2,449} \approx 0,929.$$

O resultado indica uma associação linear positiva forte entre ativo e lucro nesses dados, mas não demonstra uma relação de causa e efeito.

Quando dividir pela quantidade total de valores?

Quando os dados representam toda a população de interesse, dividimos por N , a quantidade total de pares, em vez de $n - 1$:

$$\sigma_{xy} = \frac{\sum (x_i - \mu_x)(y_i - \mu_y)}{N}, \quad \rho = \frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y}.$$

Aqui, μ_x e μ_y são as médias populacionais, e σ_x e σ_y são os desvios-padrão populacionais, também calculados com divisor N na variância. O cuidado é usar a mesma convenção nas três medidas: não misture covariância populacional com desvios-padrão amostrais.

Apêndice B

Por trás da inferência estatística

Aqui estão as justificativas das medidas de incerteza. Letras maiúsculas, como X , representam variáveis aleatórias; letras minúsculas, como x , representam os valores que observamos. A barra indica uma média.

B.1 Distribuição amostral e propriedades dos estimadores

A abreviação **i.i.d.** significa “independentes e identicamente distribuídas”: as observações não trazem informação umas sobre as outras e seguem a mesma distribuição de probabilidades. Sob essa condição, com média μ e variância finita σ^2 :

$$E(\bar{X}) = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad \text{EP}(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

A média de uma soma é a soma das médias. Para a variância, a independência faz desaparecer os termos de covariância: a soma tem variância $n\sigma^2$. Dividir a soma por n divide sua variância por n^2 , produzindo $n\sigma^2/n^2 = \sigma^2/n$.

Um estimador é **não viesado** quando sua esperança coincide com o parâmetro. É **consistente** quando, sob as condições do modelo, se aproxima do parâmetro em probabilidade à medida que a amostra cresce. São propriedades de um procedimento, não garantias de acerto em uma amostra.

Exemplo resolvido: todas as amostras de duas retiradas

Considere a população 2, 4, 6, com valores igualmente prováveis. Sua média é 4 e sua variância populacional é $8/3$. Em duas retiradas independentes com reposição, os nove pares ordenados são equiprováveis:

Primeira retirada	2	2	2	4	4	4	6	6	6
Segunda retirada	2	4	6	2	4	6	2	4	6
Média	2	3	4	3	4	5	4	5	6

As médias 2, 3, 4, 5, 6 têm probabilidades $1/9, 2/9, 3/9, 2/9, 1/9$. A média dessa distribuição é 4; a variância é $(8/3)/2 = 4/3$ e o erro-padrão é $\sqrt{4/3} \approx 1,155$. Para oito retiradas independentes, o erro-padrão é $\sqrt{(8/3)/8} \approx 0,577$.

B.2 A correção para população finita

Em uma amostragem aleatória simples sem reposição, as retiradas não são independentes: selecionar uma unidade impede que ela seja selecionada novamente. Se a variância populacional σ^2 usa divisor N , o erro-padrão exato é

$$EP(\bar{X}) = \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}, \quad N > 1.$$

O segundo fator é a correção para população finita. Se $n = N$, observamos toda a população e não há incerteza de amostragem sobre sua média. Se n for pequeno em relação a N , o fator fica próximo de 1. Dados agrupados ou temporais exigem outras considerações, não apenas essa correção.

B.3 Distribuições normal e t; fórmula geral do intervalo

Se X tem distribuição normal com média μ e desvio-padrão $\sigma > 0$, $Z = (X - \mu)/\sigma$ tem distribuição normal padrão, com média zero e variância um. Cerca de 95% de sua probabilidade está entre $-1,96$ e $1,96$.

O teorema central do limite justifica uma aproximação normal da média padronizada quando o tamanho de uma amostra i.i.d. cresce, com variância finita e positiva. Não afirma que os dados individuais se tornam normais. Não existe um tamanho mágico que elimine assimetria extrema ou dependência.

Se a população é normal e σ é desconhecido, a estatística

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

segue a distribuição t com $n - 1$ graus de liberdade. Ela acomoda a incerteza de usar S no lugar de σ e tem caudas mais pesadas que a normal padrão. Para 95% de confiança, ficam 2,5% em cada cauda. Assim, o crítico positivo deixa 97,5% à esquerda: daí o índice 0,975.

Para confiança $100(1 - \alpha)\%$, a fórmula geral é

$$\bar{x} \pm t_{1-\alpha/2, n-1} \frac{s}{\sqrt{n}}.$$

Se σ for conhecido, sob normalidade usa-se $\bar{x} \pm z_{1-\alpha/2} \sigma / \sqrt{n}$. Por exemplo, com média 50, $\sigma = 6$, $n = 36$ e confiança de 95%, o intervalo é $50 \pm 1,96(6/6) = [48,04; 51,96]$. Em populações não normais, a adequação de aproximações exige avaliar os dados e a amostragem; a fórmula exata não deve ser aplicada automaticamente.

B.4 P-valor, direção do teste e poder

Para $H_0 : \mu = \mu_0$ contra $H_1 : \mu \neq \mu_0$, nas condições do teste t da média, calcule

$$t_{\text{obs}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}, \quad p = 2P(T_{n-1} \geq |t_{\text{obs}}|).$$

As barras $|\cdot|$ indicam o módulo: usamos o tamanho da estatística sem o sinal. A letra P indica probabilidade. O fator 2 reúne as duas caudas. O p-valor é calculado supondo a hipótese nula e o modelo; não é $P(H_0 \mid \text{dados})$.

Para uma alternativa unilateral $\mu > \mu_0$, usa-se a cauda superior; para $\mu < \mu_0$, a inferior. A direção deve ser escolhida antes de ver os resultados, e não para reduzir o p-valor depois da análise.

O **poder** é a probabilidade de rejeitar uma hipótese nula falsa para uma alternativa especificada. É o complemento da probabilidade de erro tipo II. Depende do tamanho da mudança, da dispersão, da amostra e do nível de significância. Não rejeitar uma hipótese em um estudo de baixo poder não demonstra que não exista uma diferença relevante.

Apêndice C

Aprofundamentos da regressão simples

As fórmulas deste apêndice explicam resultados usados nos capítulos. Não é necessário reproduzir as demonstrações para resolver os exercícios do percurso principal.

C.1 Modelo populacional e média condicional

O modelo populacional é $Y_i = \beta_0 + \beta_1 X_i + u_i$. O termo u_i representa o desvio em relação à reta populacional. A notação $E(Y | X = x)$ significa a média de Y para um valor fixado de X . Se $E(u | X = x) = 0$, então

$$E(Y | X = x) = \beta_0 + \beta_1 x.$$

Essa hipótese de erro médio zero, chamada de exogeneidade nesse contexto, pode falhar por variáveis omitidas relacionadas a X , causalidade reversa ou certos erros de mensuração. A soma zero dos resíduos da amostra não a verifica. Mesmo uma relação bem estimada exige uma estratégia de pesquisa própria para sustentar interpretação causal.

C.2 Por que as fórmulas de MQO funcionam?

Para uma reta candidata $a + bx$, queremos minimizar $Q(a, b) = \sum [y_i - (a + bx_i)]^2$. Derivar em relação aos dois coeficientes e igualar a zero fornece as equações normais:

$$\sum (y_i - a - bx_i) = 0, \quad \sum x_i (y_i - a - bx_i) = 0.$$

A primeira dá $a = \bar{y} - b\bar{x}$; substituindo na segunda, obtemos $bS_{xx} = S_{xy}$. Se $S_{xx} > 0$, a função quadrática tem mínimo único:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Daí seguem $\sum e_i = 0$, $\sum x_i e_i = 0$ e $\bar{\hat{y}} = \bar{y}$. Quando as duas variáveis não são constantes, também vale $\hat{\beta}_1 = r s_y / s_x$.

Trocar a variável resposta muda o ajuste: a inclinação de y em x é S_{xy}/S_{xx} , enquanto a de x em y é S_{xy}/S_{yy} . Em geral elas não são recíprocas, porque minimizam desvios em direções diferentes.

C.3 Decomposição da variação e variância residual

Com intercepto, $y_i - \bar{y} = (\hat{y}_i - \bar{y}) + e_i$. Ao elevar ao quadrado e somar, o termo cruzado desaparece, pois $\sum(\hat{y}_i - \bar{y})e_i = 0$. Portanto:

$$SQ_T = SQ_{Reg} + SQ_{Res}, \quad R^2 = 1 - \frac{SQ_{Res}}{SQ_T}.$$

Na regressão simples, $SQ_{Reg} = \hat{\beta}_1^2 S_{xx} = S_{xy}^2 / S_{xx}$. Se ambas as variáveis têm variação, dividir por $S_{yy} = SQ_T$ dá $R^2 = S_{xy}^2 / (S_{xx} S_{yy}) = r^2$. As propriedades não se transferem automaticamente para modelos sem intercepto ou medidas de desempenho fora da amostra.

Como estimamos dois coeficientes, a variância residual é $s_e^2 = SQ_{Res} / (n - 2)$, para $n > 2$. Sob o modelo linear exógeno, homocedástico e com erros não correlacionados, ela estima sem viés a variância comum dos erros, σ_u^2 .

C.4 Erros-padrão e inferência dos coeficientes

Condicionalmente ao conjunto dos regressores X , assumimos erro médio zero, $E(u_i | X) = 0$, variância comum $\text{Var}(u_i | X) = \sigma_u^2$ e ausência de correlação entre erros de observações distintas. Também precisamos de $S_{xx} > 0$. As fórmulas clássicas estimadas são:

$$EP(\hat{\beta}_1) = \frac{s_e}{\sqrt{S_{xx}}}, \quad EP(\hat{\beta}_0) = s_e \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}}.$$

Para testes t exatos em pequenas amostras, assumimos adicionalmente erros normais e independentes condicionais a X . Para $j = 0$ ou $j = 1$:

$$t_j = \frac{\hat{\beta}_j - \beta_{j,0}}{EP(\hat{\beta}_j)}, \quad p_j = 2P(T_{n-2} \geq |t_j|),$$

$$IC(\beta_j) = \hat{\beta}_j \pm t_{1-\alpha/2, n-2} EP(\hat{\beta}_j).$$

No caso de horas e notas, o erro-padrão do intercepto é $\sqrt{0,8(1/5 + 9/10)} = \sqrt{0,88} \approx 0,93808$. Seu IC de 95% é aproximadamente $[-0,785; 5,185]$. O intercepto se refere a zero hora, fora da faixa observada.

C.5 Fórmulas completas dos intervalos de previsão

Para um valor x_0 especificado, a estimativa da média é $\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$. Sob o modelo clássico normal, seu erro-padrão e o de uma nova observação independente do mesmo processo são:

$$EP_{\text{média}} = s_e \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}},$$

$$EP_{\text{previsão}} = s_e \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}.$$

O termo adicional 1 representa a variância da nova resposta em torno de sua média. Use $\hat{y}_0 \pm t_{1-\alpha/2, n-2} EP$ com o erro-padrão adequado a cada pergunta. Os intervalos são mais estreitos em $x_0 = \bar{x}$. Eles são pontuais, para um x_0 fixado, e não uma faixa simultânea para toda a reta. Em extrapolação, as fórmulas não garantem que o modelo continue válido.

No exemplo das notas, em $x_0 = 3$, $EP_{\text{média}} = \sqrt{0,8/5} = 0,4$ e $EP_{\text{previsão}} = \sqrt{0,8(1 + 1/5)} \approx 0,9798$. O código abaixo calcula esses valores sem recebê-los prontos:

```
import numpy as np
from scipy import stats
horas = np.array([1, 2, 3, 4, 5], dtype=float)
notas = np.array([2, 4, 5, 4, 5], dtype=float)
ajuste = stats.linregress(horas, notas)
residuos = notas - (ajuste.intercept + ajuste.slope * horas)
variancia = (residuos ** 2).sum() / (len(horas) - 2)
soma_xx = ((horas - horas.mean()) ** 2).sum()
novo_valor = 3
previsao = ajuste.intercept + ajuste.slope * novo_valor
termo = 1 / len(horas) + (novo_valor - horas.mean()) ** 2 / soma_xx
critico = stats.t.ppf(0.975, df=len(horas) - 2)
sentidos = np.array([-1, 1])
print(previsao + sentidos * critico * np.sqrt(variancia * termo))
print(previsao + sentidos * critico * np.sqrt(variancia * (1 + termo)))
```

C.6 Alavancagem, distância de Cook e gráfico Q-Q

Um ponto de alta alavancagem está distante da média no eixo x . Um resíduo grande indica discrepância vertical em relação à reta. A influência combina essas características e depende de quanto o ajuste muda ao retirar a observação. Para regressão simples com intercepto:

$$h_i = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}, \quad r_i^{\text{pad}} = \frac{e_i}{s_e \sqrt{1 - h_i}},$$

$$D_i = \frac{e_i^2}{2s_e^2} \frac{h_i}{(1 - h_i)^2}.$$

h_i é a alavancagem, com $\sum h_i = 2$; r_i^{pad} é o resíduo internamente padronizado; D_i é a distância de Cook. As duas últimas expressões exigem $s_e > 0$ e $h_i < 1$. O limiar $4/n$ para Cook é apenas uma regra exploratória de alerta, não um teste ou ordem de exclusão.

No primeiro estudante, $h_1 = 0,6$, $e_1 = -0,8$ e $s_e^2 = 0,8$: $D_1 = (0,64/1,6)(0,6/0,16) = 1,5$. O último estudante tem a mesma alavancagem, mas $e_5 = -0,2$ e $D_5 = 0,09375$. Portanto, a mesma alavancagem não significa a mesma influência.

O gráfico **Q-Q normal** compara resíduos ordenados a quantis de uma normal. Alinhamento aproximado é compatível com a hipótese de normalidade, não uma prova. Os resíduos não são erros independentes observados: o ajuste impõe relações entre eles. Amostras pequenas limitam a capacidade de diagnóstico.

```
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats
horas = np.array([1, 2, 3, 4, 5], dtype=float)
notas = np.array([2, 4, 5, 4, 5], dtype=float)
ajuste = stats.linregress(horas, notas)
residuos = notas - (ajuste.intercept + ajuste.slope * horas)
variancia = (residuos ** 2).sum() / (len(horas) - 2)
soma_xx = ((horas - horas.mean()) ** 2).sum()
alavancagem = 1 / len(horas) + (horas - horas.mean()) ** 2 / soma_xx
cook = residuos ** 2 / (2 * variancia) * alavancagem / (1 - alavancagem) ** 2
print(alavancagem, cook)
stats.probplot(residuos, dist="norm", plot=plt)
plt.show()
```

Apêndice D

Notação de consulta rápida

Este apêndice reúne a notação adotada ao longo da Unidade I. Letras maiúsculas costumam representar quantidades antes da observação ou da população; letras minúsculas, valores observados na amostra. O significado de um símbolo depende sempre do contexto e da definição apresentada na seção correspondente.

D.1 Dados, descrição e amostragem

Grupo	Notação	Significado
Observação	i	Índice da observação.
Dados observados	x_i, y_i	Valores de X e Y na observação i . No caso central, horas de estudo e nota.
Variável aleatória	X_i, Y_i	Valores antes da observação; podem variar de uma amostra para outra.
Média amostral	$\bar{x}, \bar{y}$	Média dos valores observados de x e y .
Média populacional	μ	Média verdadeira da população.
Dispersão amostral	s, s^2	Desvio-padrão e variância amostrais.
Dispersão populacional	σ, σ^2	Desvio-padrão e variância populacionais.
Posição padronizada	z_i	Distância de uma observação à média, em desvios-padrão.
Covariância	s_{xy}	Variância conjunta amostral de X e Y .
Correlação	r	Associação linear padronizada entre duas variáveis; varia de -1 a 1 .
Tamanho amostral	n	Número de observações na amostra.

D.2 Inferência estatística

Grupo	Notação	Significado
Proporção	$p, \hat{p}$	Proporção populacional e sua estimativa amostral.
Erro-padrão	$EP(\cdot)$ ou SE	Incerteza de um estimador entre amostras; SE é a sigla em inglês.
Intervalo de confiança	$IC_{95\%}$	Faixa de valores compatíveis com os dados sob o modelo adotado.
Hipóteses	H_0, H_1	Hipótese nula e hipótese alternativa.
Nível de decisão	α	Limite previamente escolhido para a decisão de um teste, como 5%.
Teste t	t, T_{n-2}, t^*	Estatística calculada, distribuição de referência e valor crítico da distribuição t .
Graus de liberdade	gl	Quantidade que determina a distribuição t de referência; em regressão simples, $n - 2$.

D.3 Regressão linear simples

Grupo	Notação	Significado
Regressão populacional (FRP)	$Y_i = \beta_0 + \beta_1 X_i + u_i$	Relação populacional: intercepto, inclinação e erro não observado.
Regressão amostral (FRA)	$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$	Reta calculada com a amostra.
Coefficientes populacionais	β_0, β_1	Intercepto e inclinação populacionais.
Coefficientes estimados	$\hat{\beta}_0, \hat{\beta}_1$	Intercepto e inclinação estimados; o chapéu indica estimação.
Valor ajustado	$\hat{y}_i$	Valor previsto pela reta para a observação i .
Erro e resíduo	u_i, e_i	u_i é o erro populacional não observado; $e_i = y_i - \hat{y}_i$ é o resíduo calculado.
Erro residual	s_e	Tamanho típico dos desvios em torno da reta, na unidade de Y .
Somas de quadrados	SQT, SQReg, SQRes	Varição total, explicada pela regressão e residual, respectivamente.
Ajuste	R^2	Proporção da variação observada de Y reproduzida pela reta.

Cuidado com siglas de somas de quadrados

Nesta apostila, SQT é a soma de quadrados total, SQReg é a parcela explicada pela regressão e SQRes é a parcela residual. Outros livros e programas podem usar as mesmas letras com outro significado; confirme sempre a definição antes de comparar fórmulas ou resultados.

Referências Bibliográficas

- [1] ANDERSON, D. R.; SWEENEY, D. J.; WILLIAMS, T. A.; CAMM, J. D.; COCHRAN, J. J. *Estatística aplicada à administração e economia*. Edição completa, tradução da 8ª edição norte-americana. Cengage, 2021.
- [2] GUJARATI, D. N.; PORTER, D. C. *Econometria Básica*. 5. ed. Porto Alegre: AMGH, 2011.
- [3] DIEZ, D.; ÇETINKAYA-RUNDEL, M.; BARR, C. D. *OpenIntro Statistics*. 4. ed. OpenIntro, 2019. Disponível em: <https://www.openintro.org/book/os/>. Acesso em: 5 set. 2026.
- [4] OPENINTROSTAT. *OpenIntro Statistics: código-fonte do livro*. GitHub, [s. d.]. Disponível em: <https://github.com/OpenIntroStat/openintro-statistics>. Acesso em: 5 set. 2026.
- [5] AKMAN, D. *Tutorials on Data Science with Python*. [S. l.], [s. d.]. Disponível em: <https://akmand.github.io/intro.html>. Acesso em: 5 set. 2026.
- [6] XAVIER, G. *MQCC: códigos de apoio em Python*. GitHub, [s. d.]. Disponível em: <https://github.com/gustavoxavier/mqcc/tree/main/codigos>. Acesso em: 6 set. 2026.
- [7] NUMPY DEVELOPERS. *numpy.var*. Documentação do NumPy, [s. d.]. Disponível em: <https://numpy.org/doc/stable/reference/generated/numpy.var.html>. Acesso em: 5 set. 2026.
- [8] SCIPY DEVELOPERS. *scipy.stats.t*. Documentação do SciPy, [s. d.]. Disponível em: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.t.html>. Acesso em: 5 set. 2026.
- [9] SCIPY DEVELOPERS. *linregress*. Documentação do SciPy, [s. d.]. Disponível em: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.linregress.html>. Acesso em: 5 set. 2026.
- [10] NIST/SEMATECH. *e-Handbook of Statistical Methods*. Seção 1.3.5.2: Confidence Limits for the Mean. [S. l.], [s. d.]. Disponível em: <https://www.itl.nist.gov/div898/handbook/eda/section3/eda352.htm>. Acesso em: 5 set. 2026.
- [11] NIST/SEMATECH. *e-Handbook of Statistical Methods*. Seção 4.4.4: How can I tell if a model fits my data? [S. l.], [s. d.]. Disponível em: <https://www.itl.nist.gov/div898/handbook/pmd/section4/pmd44.htm>. Acesso em: 5 set. 2026.
- [12] NIST/SEMATECH. *e-Handbook of Statistical Methods*. Seção 1.3.5.11: Measures of Skewness and Kurtosis. [S. l.], [s. d.]. Disponível em: <https://www.itl.nist.gov/div898/handbook/eda/section3/eda35b.htm>. Acesso em: 5 set. 2026.

Atribuição e uso do material

Material didático da disciplina Métodos Quantitativos em Ciências Contábeis, Unidade I, Prof. Gustavo Xavier. Os exemplos, tabelas, gráficos, exercícios e roteiros computacionais desta apostila foram preparados para esta unidade com dados fictícios. Não se apresentam como

exercícios ou dados empíricos retirados das obras citadas. As referências básicas seguem a indicação bibliográfica do plano de curso apresentado no início da disciplina.

Para aprofundamento, consulte os capítulos de descrição de dados, inferência e regressão do OpenIntro (em inglês), cujo código-fonte está disponível publicamente [4]. Os tutoriais de Akman oferecem apoio adicional para o uso de Python em análise de dados [5]. Os notebooks complementares da disciplina organizam o mesmo percurso em células de Jupyter [6]; eles não substituem as práticas autossuficientes nem transformam seus exemplos em evidência empírica. A documentação oficial das bibliotecas esclarece as convenções das funções usadas na conferência.