

MÉTODOS QUANTITATIVOS EM CIÊNCIAS CONTÁBEIS

Prof. Gustavo Xavier

Unidade I – Regressão Linear Simples

❶ 1.1 Conceitos introdutórios — uma revisão

Organizar dados, reconhecer variáveis e descrever distribuições e associações.

❷ 1.2 Inferência: o que a amostra permite concluir

Quantificar incerteza, construir intervalos e interpretar testes de hipóteses.

❸ 1.3 Regressão simples: estimação, inferência e avaliação

Ajustar e interpretar uma reta, examinar resíduos e avaliar seus limites.

Como estudar os exemplos: observe a figura, tente responder à pergunta e só então confira a resolução.

Pergunta orientadora: como descrever a relação entre duas variáveis numéricas sem confundir associação, previsão e causalidade?

Roteiro computacional: do cálculo à conferência

Bloco da unidade	Notebook complementar na pasta codigos/
Descrição e visualização	ch01n2_intro_to_data.ipynb: estrutura, tipos de variável e sínteses.
Inferência	ch05_confidence_intervals.ipynb e ch07_inf_for_numerical_data.ipynb: intervalos, testes e variabilidade amostral.
Regressão e diagnóstico	ch08_simple_regression.ipynb: ajuste linear, resíduos e gráficos de diagnóstico.

Nos slides e na apostila, o caso de horas de estudo e notas é fictício e autocontido. Os notebooks ampliam a prática; antes de usar qualquer resultado, verifique a origem dos dados e as bibliotecas empregadas.

Referências: Códigos da disciplina: <https://github.com/gustavocxavier/mqcc/tree/main/codigos>; acesso em 6 set. 2026.

Da descrição dos dados à interpretação da regressão

Etapa	Pergunta que queremos responder
Descrever	Como os valores se distribuem? Quais variáveis parecem relacionadas?
Inferir	Quanto uma estimativa pode variar de uma amostra para outra?
Modelar	Como a resposta média varia com a variável explicativa?
Avaliar	Qual é a incerteza da reta? O que os resíduos e o R^2 revelam?

Uma boa análise explica os resultados em palavras, com suas unidades e limites. A fórmula organiza essa explicação; não a substitui.

Referências: Anderson et al. (2021), caps. 1–3, 7–9 e 14; Gujarati e Porter (2011), caps. 1–5.

UNIDADE I — REGRESSÃO LINEAR SIMPLES

1.1 Conceitos introdutórios — uma revisão

Tópico 1 de 3

1.1 Quem observamos e o que registramos?

- **Elemento:** entidade investigada, como um aluno ou uma empresa.
- **Variável:** característica medida em cada elemento.
- **Observação:** conjunto dos valores registrados para um elemento. Linhas são observações; colunas são variáveis.

Aluno	Sono (h)	Países	Receio (1–5)
1	5	13	3
2	7	7	2
3	5,5	1	4
4	7	—	2

Dados de uma pesquisa com alunos. O traço indica informação ausente, **não zero**.

Antes de calcular: quem foi observado, o que foi medido e em que unidade?

Referências: Anderson et al. (2021), caps. 1–3; figura/exemplo: OpenIntro, seção 1.2.

Que tipo de informação cada variável traz?

Tipo	Exemplo	Resumo inicial
Categórica nominal	Perfil introvertido/extrovertido	Frequências e gráfico de barras
Categórica ordinal	Receio da disciplina, de 1 a 5	Frequências em ordem e mediana, quando apropriada
Numérica discreta	Número de países visitados	Distribuição de contagens
Numérica contínua	Horas de sono	Histograma, média, mediana e dispersão

Um código numérico não transforma automaticamente uma categoria em uma medida quantitativa.

Referências: Anderson et al. (2021), caps. 1–3; figura/exemplo: OpenIntro, seção 1.2.

Quando faz sentido somar ou dividir valores?

Escala	Informação	Exemplo e interpretação
Nominal	Identidade de categorias	Setor econômico ou código de conta: números podem ser apenas rótulos.
Ordinal	Identidade e ordem	Rating AAA, AA, A: ordenação não implica distâncias iguais.
Intervalar	Diferenças comparáveis	Temperatura em graus Celsius: zero não significa ausência de temperatura.
Razão	Diferenças e zero significativo	Receita, ativos ou idade: razões entre valores positivos têm interpretação.

Código de conta: nominal. Uma resposta Likert de 1 a 5, isoladamente: ordinal. Codificar com números não torna a variável automaticamente quantitativa.

Referências: Anderson et al. (2021), cap. 1; Gujarati e Porter (2011), cap. 1.

O que muda quando acompanhamos a mesma empresa?

Corte transversal

Muitas unidades em um período.

Suponha uma base com o ROA de 200 empresas em 2025.

Série temporal

Uma unidade ou agregado ao longo do tempo.

Suponha uma base com a receita mensal de uma empresa por cinco anos.

Painel

Muitas unidades acompanhadas no tempo.

Suponha uma base com o ROA das mesmas 200 empresas por dez anos.

Por que reconhecer a estrutura? Medidas da mesma empresa ou de meses próximos podem ser dependentes. Mais linhas na planilha não significam mais observações independentes.

Referências: Anderson et al. (2021), cap. 1; Gujarati e Porter (2011), cap. 1.

Correr, por si só, torna a corrida mais eficiente?

PHYS ED | AUGUST 29, 2012, 12:01 AM | 21 Comments

Finding Your Ideal Running Form

By GRETCHEN REYNOLDS



David De Lossy/Getty Images

A pergunta da reportagem: é possível melhorar a forma de correr apenas com a prática?

Uma pergunta ampla pode ser investigada com um grupo muito específico. Identificar essa diferença vem antes de calcular médias ou testar hipóteses.

Quem foi observado?

Um grupo de mulheres adultas que havia ingressado recentemente em um grupo de corrida.

Antes de conhecer qualquer resultado:

- 1 Sobre quem gostaríamos de concluir algo?
- 2 Essas participantes representam todas as pessoas que correm?
- 3 O que precisaríamos saber sobre a seleção delas?

Referências: OpenIntro, seção 1.3; recorte de Gretchen Reynolds, 29/08/2012; foto: David De Lossy/Getty Images, conforme a imagem original.

Quem esse grupo de corredoras representa?

Do caso aos conceitos

População de interesse: as pessoas sobre as quais queremos concluir algo. A pergunta inicial falava de pessoas em geral.

Amostra: as mulheres adultas do grupo observado.

Censo: observar toda a população definida.


O alcance depende da seleção

- Não há base para estender automaticamente o resultado a crianças, homens ou atletas profissionais.
- Nem todas as mulheres adultas estão necessariamente representadas.
- Conveniência, voluntariado e não resposta podem distorcer a amostra.

Mesmo uma amostra grande pode ser enviesada. A generalização exige definir a população e justificar como as participantes a representam.

Referências: Anderson et al. (2021), cap. 7; OpenIntro, seção 1.3, caso da corrida.

Uma pesquisa com 2,4 milhões de respostas pode errar?



Eleição dos EUA, 1936: a revista *Literary Digest* enviou cerca de 10 milhões de questionários e recebeu aproximadamente 2,4 milhões de respostas.

- A pesquisa previa a vitória de Landon: Roosevelt teria cerca de 43% dos votos.
- Roosevelt venceu com cerca de 62% dos votos.

Quem tinha chance de responder?


As listas incluíam leitores da revista, proprietários de automóveis e usuários de telefone. Esses grupos não representavam igualmente o eleitorado; muitos destinatários também não responderam.

O problema estava apenas no tamanho da amostra? Não: ampliar uma seleção enviesada não corrige quem ficou de fora. Cobertura e não resposta importam.

Referências: OpenIntro, seção 1.3, caso *Literary Digest*; percentuais históricos arredondados.


Como selecionar a amostra? Compare os desenhos

Aleatória simples




Sortear indivíduos a partir da lista de toda a população.

Estratificada



Dividir em estratos e sortear indivíduos de **cada** estrato.

Por conglomerados



Sortear alguns grupos e observar **todos** os indivíduos desses grupos.

Aplique à pesquisa com alunos

Sortear alunos de **todas as turmas**: amostragem estratificada por turma. Sortear **algumas turmas inteiras**: amostragem por conglomerados.

Nos diagramas, os pontos vermelhos indicam os indivíduos selecionados. Compare: pessoas em todos os grupos ou grupos inteiros?

Referências: Anderson et al. (2021), cap. 7; figura/exemplo: OpenIntro, seção 1.3; diagramas originais e aplicação didática à pesquisa com alunos.

Observar uma relação é o mesmo que testar uma causa?

Estudo observacional

O pesquisador observa como os dados surgem, sem atribuir tratamentos.

- Permite descrever associações.
- Pode haver fatores de confusão.

Experimento aleatorizado

O pesquisador atribui tratamentos aleatoriamente.

- A aleatorização ajuda a equilibrar fatores de confusão.
- Um delineamento adequado sustenta inferências causais.

Amostragem aleatória: a quem generalizar?

Atribuição aleatória: o tratamento causou a diferença?

Referências: Anderson et al. (2021), caps. 1–3; figura/exemplo: OpenIntro, seções 1.2 e 1.4.

Como testar se um gel energético melhora o tempo de corrida?



Produto ilustrado no exercício original.

Planejamento de um experimento, não um resultado observado.

Se todos os profissionais recebessem gel e todos os amadores ficassem sem gel, uma diferença de tempo seria devida ao produto ou ao nível de treinamento?

Uma comparação mais justa: formar blocos

- 1 Separar atletas profissionais e amadores.
- 2 Sortear, **dentro de cada grupo**, quem recebe gel e quem fica sem gel.
- 3 Comparar os tempos mantendo as condições da prova semelhantes.

Bloco é uma característica anterior ao tratamento; gel é o tratamento atribuído. Estratificar ajuda a selecionar a amostra; bloquear ajuda a organizar o experimento.

Referências: OpenIntro, seção 1.4, exercício de planejamento com gel energético; imagem original.

Experimento: o gênero indicado altera a promoção?

Experimento histórico: 48 supervisores receberam um mesmo perfil profissional; apenas o gênero indicado variava, com atribuição aleatória de 24 fichas a cada grupo.

Ficha	Promovido	Não	Total
Masculina	21	3	24
Feminina	14	10	24

$$\frac{21}{24} = 87,5\%, \quad \frac{14}{24} \approx 58,3\%.$$


Leia antes de concluir:

- 1 Qual variável foi manipulada?
O gênero indicado na ficha.
- 2 Qual foi a resposta?
A decisão de promoção.
- 3 A diferença é de quanto?
Cerca de 29,2 pontos percentuais.

A aleatorização permite investigar um efeito nesse experimento. Mas a diferença observada poderia surgir apenas pela atribuição aleatória das fichas?

Referências: Anderson et al. (2021), caps. 1–3; figura/exemplo: OpenIntro, seção 2.3; estudo de Rosen e Jerdee (1974), apresentado no material.

Qual setor aparece com mais frequência?



Suponha uma base com **100 empresas**, distribuídas entre os setores abaixo:

- Comércio: 32 empresas, ou 32%.
- Serviços: 48 empresas, ou 48%.
- Indústria: 20 empresas, ou 20%.

Pergunta: qual categoria é a moda?
Serviços, a categoria mais frequente.

Como $n = 100$, contagens e percentuais têm o mesmo valor numérico neste exemplo. Isso não vale em geral: frequência relativa = frequência absoluta / total.

Referências: Anderson et al. (2021), cap. 2.

Comparar apenas o número de sobreviventes é justo?

Titanic	Mortos	Sobreviventes	Total
Adultos	1438	654	2092
Crianças	52	57	109
Total	1490	711	2201

Sobrevivência dentro de cada grupo:


$$\frac{654}{2092} \approx 31,3\% \quad \frac{57}{109} \approx 52,3\%.$$

Houve mais sobreviventes adultos em número absoluto, mas maior **proporção de sobreviventes** entre as crianças.

Em tabelas de contingência, o denominador deve corresponder ao grupo sobre o qual a pergunta é feita.

Referências: Anderson et al. (2021), caps. 1–3; figura/exemplo: OpenIntro, seção 2.2.

Titanic: enxergando as proporções no gráfico



Como ler:


- 1 Cada barra representa 100% de um grupo etário.
- 2 Compare a parcela clara: sobreviventes (*Survived*).
- 3 Crianças (*Child*): cerca de 52%; adultos (*Adult*): cerca de 31%.

Pergunta: por que as barras têm a mesma altura se há muito mais adultos?

Porque o gráfico usa **proporções dentro de cada grupo**, não contagens. Ele torna comparáveis grupos de tamanhos diferentes.

Referências: Anderson et al. (2021), caps. 1–3; figura/exemplo: OpenIntro, seção 2.2; gráfico de barras empilhadas padronizadas.

O que o gráfico revela antes de calcular uma média?




- **Forma:** simétrica ou assimétrica? Quantas modas?
- **Centro:** onde se concentram os valores?
- **Dispersão:** quão espalhados estão?
- **Valores atípicos:** há observações muito afastadas?

Histogramas agrupam valores numéricos em intervalos; gráficos de barras comparam categorias.

Referências: Anderson et al. (2021), caps. 1–3; figura/exemplo: OpenIntro, seções 2.1 e 2.2.

Qual margem operacional parece mais comum?



Suponha uma base com as **margens operacionais de 25 empresas**, distribuídas como no gráfico.




- 1 Em que faixa se concentra a maior parte das margens?
- 2 Há observações distantes do centro?
- 3 A cauda direita é mais longa?

Leitura: concentração aproximadamente entre 2,5% e 5%, com valores mais altos chegando a 8,1%.

A descrição deve combinar forma, centro, dispersão e possíveis extremos; a média sozinha não mostra tudo isso.

Mudou o histograma: mudaram os dados?

Observe: horas semanais dedicadas a atividades extracurriculares, na pesquisa com alunos. Os dados são os mesmos nos três painéis.



Discuta e confira

Classes largas podem esconder detalhes; classes muito estreitas podem realçar flutuações. Os eixos verticais têm escalas diferentes: compare a forma, não apenas a altura das barras entre painéis.

Referências: Anderson et al. (2021), caps. 1–3; figura/exemplo: OpenIntro, seção 2.1; figuras originais sobre a escolha de classes do histograma.

Uma renda muito alta representa a maioria?

Ao elevar a maior renda para US\$ 10 milhões, a média sobe de US\$ 245 mil para US\$ 309 mil; a mediana permanece em US\$ 190 mil. Qual descreve melhor a renda típica?


$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i.$$

n : total de observações; i : posição na amostra. $\sum_i$ soma os n valores; $\bar{x}$ é a média.


Medida	O que usa	Limitação ou vantagem
Média	Todos os valores quantitativos	Sensível a valores extremos.
Mediana	A posição central nos dados ordenados	Mais resistente à assimetria e a valores extremos.
Moda	A maior frequência	Serve também para categorias; pode não ser única.

Referências: Anderson et al. (2021), cap. 3; exemplo de renda: OpenIntro, seção 2.1.

A mesma média significa resultados igualmente previsíveis?



Média do grupo A: $\bar{x}_A = 5$.



Média do grupo B: $\bar{x}_B = 5$.

Se tentássemos prever o próximo valor apenas pela média, em qual grupo esperaríamos menos erro? O grupo A é mais concentrado; a média sozinha esconde essa diferença.

Exemplo didático; não se trata de uma base de dados real.
Referências: Anderson et al. (2021), cap. 3.

Somar os desvios revela a dispersão dos dados?

Retome o grupo B: 1; 3; 5; 7; 9. Sua média é $\bar{x} = 25/5 = 5$.

Observação i	Valor x_i	Desvio $x_i - \bar{x}$	Desvio ao quadrado $(x_i - \bar{x})^2$
1	1	-4	16
2	3	-2	4
3	5	0	0
4	7	2	4
5	9	4	16
Soma	25	0	40

$$\sum_{i=1}^5 (x_i - \bar{x}) = 0, \quad \sum_{i=1}^5 (x_i - \bar{x})^2 = 40 > 0.$$

Desvios de sinais opostos se cancelam: soma zero **não significa ausência de dispersão**. Os quadrados não se cancelam; sua soma só é zero quando todos os valores são iguais.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), cap. 3.

Quanto os valores se afastam da média?


- $x_i - \bar{x}$: afastamento de cada valor em relação à média.
- O quadrado impede o cancelamento entre desvios positivos e negativos e dá maior peso aos extremos.
- Estimar a média impõe $\sum_i (x_i - \bar{x}) = 0$: restam $n - 1$ graus de liberdade.
- s^2 tem unidade ao quadrado; s volta à unidade original da variável.

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}, \quad s = \sqrt{s^2}.$$

Nos grupos anteriores: $s_A \approx 0,79$ e $s_B \approx 3,16$. O desvio-padrão confirma o que vimos no gráfico. Se $s = 0$, todos os valores são iguais.

Referências: Anderson et al. (2021), cap. 3; Gujarati e Porter (2011), Apêndice A.

Um valor distante é necessariamente um erro?



- Caixa: do percentil 25 (Q_1) ao percentil 75 (Q_3); linha central: mediana (Q_2).
- $IQR = Q_3 - Q_1$: amplitude interquartil, que abrange os 50% centrais. Bigodes: extremos dentro dos limites usuais.
- Sinalizadores de possíveis valores atípicos:

$$x < Q_1 - 1,5IQR$$

$$x > Q_3 + 1,5IQR.$$

Investigue erros de registro e o contexto. Um ponto atípico pode ser uma observação legítima e importante.

O valor 13 é alto? Depende do que usamos como referência

- $z = 0$: exatamente na média.
- $z = +2$: dois desvios-padrão acima da média.
- $z = -1,5$: um e meio desvio-padrão abaixo da média.

Como interpretar o valor 13?

Suponha que a média de um indicador seja 10 e o desvio-padrão seja 2. O valor 13 tem

$$z = \frac{13 - 10}{2} = 1,5.$$


Está 1,5 desvio-padrão acima da média.

$$z_i = \frac{x_i - \bar{X}}{s_x}, \quad s_x > 0.$$

Padronizar não exige normalidade. Usar a normal para converter um escore z em percentil exige justificar esse modelo de distribuição.

Referências: Anderson et al. (2021), cap. 3; conexão com a correlação e com a revisão de inferência.

Onde a escolaridade é maior, a pobreza costuma ser menor?




Exemplo histórico: 50 estados dos EUA e Distrito de Columbia.

- x : percentual com ensino médio concluído (eixo horizontal).
- y : percentual em situação de pobreza (eixo vertical).
- Tendência negativa, aproximadamente linear.


Pergunta: como resumir essa associação com uma reta?

Referências: Anderson et al. (2021), caps. 1–3; figura/exemplo: OpenIntro, seções 1.2 e 8.1.


Qual associação é mais linear?




(a)



(b)



(c)



(d)

Qual painel tem os pontos mais próximos de uma reta?

- (a): há um padrão claro, mas curvo.
- (b): pontos próximos de uma reta crescente.
- (c): tendência crescente, com grande dispersão.
- (d): tendência decrescente.

Confira: o painel **(b)**. Direção e alinhamento são coisas diferentes.

Correlação mede associação **linear**, não qualquer padrão. Uma relação não linear pode ser forte e, ainda assim, não ser bem resumida por uma reta.

Referências: Anderson et al. (2021), cap. 3; figura/exemplo: OpenIntro, seção 8.1; exercício visual de correlação do material original.

Covariância: as duas variáveis variam juntas?

- $s_{xy} > 0$: a soma dos produtos dos desvios é positiva.
- $s_{xy} < 0$: a soma desses produtos é negativa.
- $s_{xy} = 0$: os produtos se compensam; isso não garante independência.

Observe o produto

Acima das duas médias: $(+)(+) > 0$.

Abaixo das duas médias: $(-)(-) > 0$.

Acima de uma e abaixo da outra: $(+)(-) < 0$.

A unidade é o produto das unidades de X e Y .

$$s_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}.$$

Converter receita de reais para milhões de reais muda a magnitude da covariância. Por isso, ela não oferece uma escala universal de intensidade.

Referências: Anderson et al. (2021), cap. 3, medidas de associação.

Como comparar a força de associações em escalas diferentes?

- O sinal informa a direção; $|r|$ informa a intensidade da associação linear.
- Correlação próxima de zero não exclui uma relação não linear.
- Trocar X por Y mantém r ; converter unidades por fatores positivos também.
- Se multiplicarmos uma variável por um número negativo, o sinal de r se inverte.

$$r = \frac{s_{xy}}{s_x s_y}, \quad -1 \leq r \leq 1 \quad (s_x, s_y > 0).$$

s_{xy} é a covariância amostral; s_x e s_y são os desvios-padrão amostrais.

Qual associação linear é mais forte: $r = -0,90$ ou $r = +0,40$? A primeira: $0,90 > 0,40$ em valor absoluto. Negativa não significa fraca.

Referências: Anderson et al. (2021), cap. 3; Gujarati e Porter (2011), cap. 1.

Checagem de 1.1: descrever antes de modelar

Tente responder	Confira o conceito
Rating AAA/AA/A é quantitativo?	Não: categoria ordinal.
Dois grupos com mesma média são iguais?	Não: compare dispersão, forma e extremos.
O que informa covariância negativa?	A soma dos produtos dos desvios é negativa; a magnitude depende das unidades.
$r = 0,80$ prova causalidade?	Não. Veja o desenho do estudo e possíveis confundidores.
O que ver antes de calcular correlação?	Diagrama de dispersão: direção, forma, força e pontos atípicos.

Distinguir variabilidade, associação e causalidade prepara a leitura da regressão.


Referências: Anderson et al. (2021), caps. 1–3; Gujarati e Porter (2011), cap. 1.

UNIDADE I — REGRESSÃO LINEAR SIMPLES

1.2 Inferência: o que a amostra permite concluir

Tópico 2 de 3

Uma colher de sopa basta para avaliar a panela inteira?



Pense antes de concluir:

- A colher parece pouco salgada. Podemos dizer o mesmo da panela?
- E se o sal estiver acumulado no fundo e a colher vier da superfície?
- O que muda se misturarmos antes de provar?

Duas afirmações diferentes

Descrição: esta colher está pouco salgada.

Inferência: a panela está pouco salgada.

Na analogia, misturar ajuda a obter uma colher representativa. Uma coleta enviesada não se corrige apenas calculando uma margem de erro.

Referências: OpenIntro, seção 1.3, analogia da sopa; desenho esquemático.

1.2 Como aprender sobre a população com uma amostra?

Quantidade	Parâmetro populacional	Estatística amostral
Média	μ	$\bar{x}$
Proporção	p	$\hat{p}$
Inclinação da regressão	β_1	$\hat{\beta}_1$

- Amostras diferentes geram estimativas diferentes: **variabilidade amostral**.
- O **erro-padrão (EP)** quantifica a dispersão da distribuição amostral de uma estatística.
- Viés é uma tendência sistemática; aumentar n não o elimina necessariamente.

$\hat{p}$ e $\hat{\beta}_1$ são **estimadores** de p e β_1 , respectivamente. Os valores obtidos em uma amostra para esses estimadores são **estimativas** dos verdadeiros valores dos parâmetros p e β_1 .

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 5.1; conexão com a seção 8.4.

Se mudarmos a amostra, a estimativa muda?

Estimador: a regra


$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

X_i representa um valor antes de observá-lo. Assim, $\bar{X}$ pode variar de uma amostra para outra.

Estimativa: o resultado

Suponha que uma amostra produza $\bar{x} = 7,4$. A letra minúscula indica o resultado obtido com os valores observados x_i .

Outras amostras da mesma população poderiam produzir $\bar{x}_A = 7,2$ ou $\bar{x}_B = 7,8$.



Diferenças entre estimativas não são necessariamente erros de cálculo: refletem variabilidade amostral. Em regressão, o mesmo vale para $\hat{\beta}_0$ e $\hat{\beta}_1$.

Referências: Anderson et al. (2021), cap. 7; Gujarati e Porter (2011), cap. 2.

Mais dados reduzem a dispersão ou a incerteza?


	Desvio-padrão s	Erro-padrão: EP ou SE
Objeto	Observações individuais	Estimador entre amostras
Pergunta	Quão dispersos são os dados?	Quão incerta é a estimativa?
Efeito de aumentar n	Não diminui necessariamente	Em condições usuais, tende a diminuir
Na regressão	Dispersão de X ou de Y	Incerteza de $\hat{\beta}_0$ e de $\hat{\beta}_1$

$$EP(\bar{X}) = \frac{\sigma}{\sqrt{n}}, \quad EP(\bar{x}) = \frac{s}{\sqrt{n}}.$$

σ é o desvio-padrão populacional; s , o amostral. Nos cálculos, EP indica o erro-padrão estimado com os dados; SE é a sigla em inglês.

Mais dispersão nos dados aumenta a incerteza. Para reduzir o EP da média à metade, mantendo σ e o desenho amostral, é preciso quadruplicar n .

Como transformar uma distância em probabilidade?




- μ é a média; σ é o desvio-padrão; σ^2 é a variância. O símbolo $\sim$ se lê “tem distribuição”.
- Áreas sob a curva representam probabilidades.
- Aproximadamente 68%, 95% e 99,7% ficam a até 1, 2 e 3 desvios-padrão da média.

$$X \sim N(\mu, \sigma^2), \quad Z = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

Para 95% de área central na normal padrão, o valor crítico mais preciso é $z^* \approx 1,96$.

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 4.1.

Exemplo: como comparar notas em escalas diferentes?



Pergunta: Pam tirou 1800 no SAT; Jim tirou 24 no ACT. Quem ficou mais acima da média de sua prova?

Parâmetros do exemplo histórico:

$$\text{SAT: } \mu = 1500, \sigma = 300;$$

$$\text{ACT: } \mu = 21, \sigma = 5.$$

Padronize antes de comparar:

$$z_{\text{Pam}} = \frac{1800 - 1500}{300} = 1,$$


$$z_{\text{Jim}} = \frac{24 - 21}{5} = 0,6.$$

Pam ficou 1 desvio-padrão acima da média; Jim, 0,6. Assim, **Pam teve maior posição relativa**, não porque 1800 seja maior que 24.

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 4.1; escalas e parâmetros históricos do exemplo, não dos exames atuais.

Qual parcela das embalagens fica fora da especificação?

Exercício de controle de qualidade: o conteúdo de uma embalagem de ketchup é modelado pela normal, com média 36 e desvio-padrão 0,11 onça (oz).



Área central: embalagens entre 35,8 e 36,2 oz. As duas caudas representam reprovações na inspeção.

Antes de calcular: basta olhar a cauda da esquerda para contar todas as reprovações?

Não. Também são reprovadas embalagens **acima** de 36,2 oz.


$$z_{\text{inferior}} = \frac{35,8 - 36}{0,11} \approx -1,82.$$

O limite superior está à mesma distância da média: $z_{\text{superior}} \approx 1,82$.

Pelo modelo, cerca de 93,1% passam e 6,9% ficam fora dos limites. A área sob a curva transforma a dispersão do processo em uma proporção esperada de embalagens.

Referências: OpenIntro, seção 4.1, exercício de envase de ketchup; probabilidades calculadas sem arredondar os escores intermediários.

Que padrão aparece ao reunir muitas médias amostrais?



Valores possíveis da média amostral

Esquema da distribuição de muitas médias, **não dos dados individuais**.

- Repetir a amostragem gera diferentes $\bar{x}$.
- Para observações independentes e identicamente distribuídas, com variância finita:


$$E(\bar{X}) = \mu, \quad EP(\bar{X}) = \frac{\sigma}{\sqrt{n}}.$$

- Com n suficientemente grande, a distribuição da média se aproxima da normal; o tamanho necessário depende da população.

O TCL não torna os dados originais normais nem corrige viés de seleção.

Referências: Anderson et al. (2021), cap. 7; Gujarati e Porter (2011), Apêndice A; esquema didático.

Por que a pesquisa não encontra sempre o mesmo percentual?



Eixo horizontal: proporção estimada **em cada amostra**;
barras: quantas simulações produziram valores semelhantes.

Por que nem toda amostra resulta em 88%? Por **variabilidade amostral**. As estimativas oscilam cerca de 1 ponto percentual por erro-padrão, mesmo sem viés.

Simulação de amostragem:

- 1 Fixar uma população com $p = 0,88$ de apoio à energia solar.
- 2 Sortear $n = 1000$ pessoas e calcular $\hat{p}$.
- 3 Repetir 10 000 vezes e reunir as 10 000 estimativas.

$$EP(\hat{p}) \approx \sqrt{\frac{0,88 \cdot 0,12}{1000}} \approx 0,0103.$$

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 5.1; simulação ilustrativa, não uma estimativa de opinião atual.

Antes da fórmula: estimar um ponto ou um intervalo?

Uma lança: mirar em um ponto



Uma estimativa pontual, como $\hat{p} = 0,67$, fornece um único valor, mas não mostra sua incerteza.

Para os mesmos dados, exigir maior confiança amplia o intervalo. O método deve calibrar a troca entre precisão e confiança: **estimativa $\pm$ margem de erro**.


Uma rede: cobrir uma faixa



Um intervalo amplia a faixa de valores plausíveis. A largura expressa um compromisso entre precisão e confiança.

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 5.2; analogia e fotos do original: Chris Penny (lança) e Mark Fischer (rede).

Quanto confiar na precisão de uma estimativa?



- Suponha uma amostra cuja média seja $\bar{x} = 7,4$.
- Com margem de erro 0,5, o intervalo é $[6,9; 7,9]$.
- A margem é calculada com o nível de confiança, a distribuição de referência e o erro-padrão;

estimativa $\pm$ valor crítico $\times$ erro-padrão.

Na regressão, a mesma estrutura será aplicada a $\hat{\beta}_1$ para estimar a inclinação populacional β_1 .

Referências: Anderson et al. (2021), cap. 8; Gujarati e Porter (2011), Apêndice A.

49% significa que sabemos o percentual exato?

Pesquisa histórica, EUA, dezembro de 2011: entre adultos de 18 a 34 anos, 49% disseram ter aceitado um emprego que não queriam apenas para pagar as contas.

Tough economic times altering young adults' daily lives, long-term plans. While negative trends in the labor market have been felt most acutely by the youngest workers, many adults in their late 20s and early 30s have also felt the impact of the weak economy. Among all 18- to 34-year-olds, fully half (49%) say they have taken a job they didn't want just to pay the bills, with 24% saying they have taken an unpaid job to gain work experience. And more than one-third (35%) say that, as a result of the poor economy, they have gone back to school. Their personal lives have also been affected: 31% have postponed either getting married or having a baby (22% say they have postponed having a baby and 20% have put off getting married). One-in-four (24%) say they have moved back in with their parents after living on their own.

O trecho destacado apresenta o resultado para os jovens entrevistados.

O relatório informa: margem de erro de 4,4 pontos percentuais para o grupo de 18 a 34 anos, com 95% de confiança.

$$49\% \pm 4,4 \text{ p.p.}$$

$$IC_{95\%} = [44,6\%; 53,4\%].$$

Podemos afirmar que menos da metade da população passou por isso? O intervalo inclui 50%: essa conclusão não é sustentada pelo intervalo.

A margem da pesquisa completa era 2,9 p.p., mas a do subgrupo era 4,4 p.p. Use a margem correspondente ao grupo sobre o qual está falando.

Referências: OpenIntro, seção 5.1; recortes Pew Research, pesquisa de 6 a 19/12/2011; margens informadas no relatório.

Intervalo de confiança para uma proporção

Em uma pesquisa histórica com 850 usuários americanos do Facebook, 67% consideraram correta a classificação de seus interesses.

$$\hat{p} = 0,67, \quad EP(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} = \sqrt{\frac{0,67 \cdot 0,33}{850}} \approx 0,0161.$$

$$IC_{95\%}(p) : \hat{p} \pm 1,96 EP(\hat{p}) \approx [0,638; 0,702].$$

- Aproximação normal: requer observações independentes e contagens esperadas adequadas; no IC, verificar $n\hat{p} \geq 10$ e $n(1 - \hat{p}) \geq 10$.
- Em amostragem sem reposição, a regra $n \leq 10\%$ da população ajuda a justificar a aproximação de independência.

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 5.2; pesquisa Pew de 2019, conforme o material-fonte.

O que significa confiança de 95%?

Interpretação do procedimento

Se repetíssemos a amostragem e construíssemos os intervalos pelo mesmo método, aproximadamente 95% deles conteriam o parâmetro verdadeiro, sob as condições do método.

- O intervalo não contém necessariamente 95% dos valores individuais.
- Na interpretação frequentista, o parâmetro é fixo; o intervalo varia entre amostras.
- Maior confiança exige, em geral, um intervalo mais amplo.
- Maior amostra tende a reduzir a margem de erro, mantendo o mesmo procedimento.


No exemplo: estimamos que a proporção populacional estava entre 63,8% e 70,2%, com 95% de confiança. Não é uma estimativa da situação atual.

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 5.2.

Por que usar t quando o desvio-padrão é desconhecido?

$$EP(\bar{x}) = \frac{s}{\sqrt{n}}, \quad gl = n - 1.$$

$$IC_{95\%}(\mu) : \bar{x} \pm t_{n-1}^* EP(\bar{x}).$$



Observe as caudas: a curva t reserva mais probabilidade para valores extremos que a normal.


- gl significa graus de liberdade; t_{n-1}^* é o valor crítico para 95% de confiança, com $n - 1$ gl .
- Como estimamos σ por s , usamos t : o intervalo é exato para observações independentes de uma população normal.
- Com poucos dados, investigar assimetria e valores atípicos é essencial.

Para 95% de confiança e 9 graus de liberdade, $t^* \approx 2,262 > 1,96$: a margem de erro é maior que a obtida usando a normal.

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 7.1; comparação gráfica das distribuições normal e t .

O fluxo de veículos muda entre as sextas-feiras 6 e 13?

Pergunta: há diferença no fluxo médio? Cada par compara o mesmo local e mês. Defina $d = \text{fluxo no dia 6} - \text{fluxo no dia 13}$.



Leia o sinal: diferenças positivas indicam mais veículos no dia 6. O histograma mostra **dez diferenças**, não 20 contagens independentes.

1. **Resumir:** $n = 10$, $\bar{d} = 1835,8$, $s_d = 1176,0$.

2. **Quantificar incerteza:**

$$EP(\bar{d}) = \frac{1176,0}{\sqrt{10}} \approx 371,9.$$

3. **Construir o IC de 95%:**

$$1835,8 \pm 2,262 \cdot 371,9$$

$$\approx [994,5; 2677,1] \text{ veículos.}$$

O IC fica acima de zero, sob as hipóteses do método. É preciso avaliar independência entre diferenças e normalidade; a comparação observacional **não identifica uma causa**.

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 7.1; dados de 1990–1992 e histograma originais.

A diferença observada seria surpreendente sob a hipótese?

- 1 Defina H_0 (hipótese nula, referência) e H_1 (alternativa) sobre um **parâmetro**.
- 2 Escolha previamente o nível de significância α , como 5%, e verifique as condições.
- 3 Calcule uma estatística e sua distribuição sob H_0 .
- 4 Obtenha o valor-p e formule uma conclusão no contexto.

Valor-p

Probabilidade, supondo H_0 e o modelo do teste válidos, de obter uma estatística tão ou mais extrema que a observada, na direção de H_1 .

Nas fórmulas, P indica probabilidade. Em testes bilaterais simétricos, o fator 2 soma as probabilidades das duas caudas.

valor-p $\leq \alpha$: rejeitar H_0 . Caso contrário: não rejeitar H_0 .
O valor-p **não** é a probabilidade de H_0 ser verdadeira.

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 5.3.

Exemplo: o tempo médio de processamento é 10 minutos?

Suponha uma amostra de tempos de processamento com $n = 25$, $\bar{x} = 11,2$ minutos e $s = 2$ minutos. Admita observações independentes de uma população aproximadamente normal.

1. Formular e padronizar

$$H_0 : \mu = 10, \quad H_1 : \mu \neq 10.$$

$$EP(\bar{x}) = \frac{2}{\sqrt{25}} = 0,4.$$

$$t = \frac{11,2 - 10}{0,4} = 3, \quad \text{gl} = 24.$$

2. Comparar com a distribuição t


$t = 3$ é o resultado observado. T_{24} é uma variável com distribuição t de 24 graus de liberdade.

$$\text{valor-p} = 2P(T_{24} \geq 3) \approx 0,0062.$$

Com $\alpha = 5\%$ definido previamente, rejeitamos H_0 : há evidência de diferença em relação a 10 minutos.

A diferença de 1,2 minuto é grande em relação à sua incerteza de 0,4 minuto? O teste responde a essa comparação, sob as condições assumidas.

Promoções: a diferença poderia ocorrer apenas por acaso?



Cada ponto corresponde a uma das 100 simulações de diferenças entre proporções, **sob a hipótese de nenhum efeito**.

No teste bilateral, conte resultados com $|D| \geq 0,292$ nas **duas caudas**. Essa frequência aproxima o valor-p; 100 simulações ilustram a lógica, mas dão pouca precisão.

Retome o caso das fichas:

$$|D_{\text{obs}}| = \left| \frac{21}{24} - \frac{14}{24} \right| \approx 0,292.$$

- 1 Manter 35 promoções e 13 não promoções.
- 2 Embaralhar os rótulos de gênero, preservando 24 fichas por grupo.
- 3 Recalcular a diferença e repetir.

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 2.3; distribuição de randomização apresentada no material.

Observar 67% seria surpreendente se a proporção fosse 50%?

Na pesquisa com usuários do Facebook, 67% consideraram correta a classificação de seus interesses. Esse percentual seria incomum se, na população, apenas metade concordasse?

$$H_0 : p = p_0, \quad H_1 : p \neq p_0, \quad z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}.$$

- Retome a pesquisa com $\hat{p} = 0,67$. Se a hipótese é $p_0 = 0,50$, o erro-padrão do teste usa 0,50, não 0,67.
- Verificar independência e $np_0 \geq 10$, $n(1 - p_0) \geq 10$ para a aproximação normal.
- $Z \sim N(0, 1)$ é a referência: valor-p = $2P(Z \geq |z|)$. As barras $|z|$ indicam a distância de z a zero.
- Uma alternativa unilateral, $p > p_0$ ou $p < p_0$, deve ser justificada antes da análise.

O teste pergunta se 67% seria incomum em amostras de uma população com 50%. A variabilidade de referência vem da hipótese; a do IC é estimada com os dados.

Que erros podemos cometer ao decidir sobre uma hipótese?

Decisão	H_0 verdadeira	H_0 falsa
Rejeitar H_0	Erro tipo I	Decisão correta
Não rejeitar H_0	Decisão correta	Erro tipo II

- α : probabilidade de erro tipo I, sob as condições do teste.
- Erro tipo II: probabilidade β para uma alternativa específica; poder = $1 - \beta$. Esse β não é um coeficiente da regressão.
- Não rejeitar H_0 não prova ausência de efeito.
- Um efeito pequeno pode ser estatisticamente significativo em uma amostra grande.


Relate a estimativa, a unidade e o intervalo de confiança; não apenas se o valor-p ficou abaixo de 0,05.

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, seção 5.3.

O intervalo e o teste levam à mesma conclusão?

Retome o processamento: o IC de 95% para a média é

$$11,2 \pm t_{24}^* \cdot 0,4 \approx 11,2 \pm 2,064 \cdot 0,4 = [10,37; 12,03] \text{ minutos.}$$



- O valor 10 fica fora do IC: isso concorda com a rejeição no teste bilateral a 5%.
- A equivalência exige **teste e intervalo correspondentes**, com o mesmo modelo, erro-padrão e nível.

Não aplique essa equivalência automaticamente a fórmulas distintas, como certos testes e intervalos aproximados para proporções.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), caps. 8–9; Gujarati e Porter (2011), cap. 5.

Da revisão de inferência à regressão

Pergunta	Parâmetro	Ferramenta clássica
Qual a proporção?	p	IC/teste com aproximação normal, se adequada
Qual a média?	μ	IC/teste t ; $gl = n - 1$
Como a média de Y varia com X ?	Inclinação β_1	IC/teste t na regressão simples; $gl = n - 2$

Estrutura comum: estimativa $\pm$ valor crítico $\times$ erro-padrão.

O parâmetro, o erro-padrão e as condições mudam conforme a pergunta.

Referências: Anderson et al. (2021), caps. 7–9; gráfico/exemplo: OpenIntro, capítulo 5 e seções 7.1 e 8.4.

Checagem de 1.2: da estimativa à evidência


Tente responder	Confira o conceito
Parâmetro e estatística são iguais?	Um descreve a população; a outra é calculada na amostra.
Estimador ou estimativa?	Regra versus resultado numérico.
O EP mede a dispersão de quê?	Do estimador entre amostras.
O que significa confiança de 95%?	Cobertura do procedimento em repetições, sob suas condições.
valor-p = 0,30 prova ausência de efeito?	Não. É insuficiência de evidência contra a hipótese testada.
Qual comparação reaparece na regressão?	(estimativa – valor nulo)/EP.

Referências: Anderson et al. (2021), caps. 7–9; Gujarati e Porter (2011), Apêndice A.

1.3 Regressão simples: estimação, inferência e avaliação

Tópico 3 de 3

1.3 Qual reta representa melhor os dados?



Retome o exemplo: x é o percentual com ensino médio concluído; y , o percentual em situação de pobreza, nos 50 estados e DC.

Antes de calcular, escolha (a), (b), (c) ou (d):

- 1 A reta acompanha a direção dos pontos?
- 2 Passa perto do centro da nuvem?
- 3 Deixa desvios razoavelmente equilibrados acima e abaixo?


A inspeção visual sugere a reta **(a)**. O critério de mínimos quadrados permite justificar a escolha comparando os resíduos.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–5; OpenIntro, seções 8.1 e 8.2; comparação de retas do material original.

Quem estuda mais tende a obter notas maiores?

i	Estudo x (h)	Nota y
1	1	2
2	2	4
3	3	5
4	4	4
5	5	5

$$\bar{x} = 3, \quad \bar{y} = 4.$$



Suponha uma base com estes cinco alunos: x_i são horas de estudo e y_i é a nota do aluno i . Sem calcular, a inclinação parece positiva, negativa ou próxima de zero?

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–3.

A reta prevê a nota de cada aluno ou uma nota média?

Mesmas horas, resultados diferentes

Imagine dois alunos que estudaram três horas. Eles necessariamente terão a mesma nota?

Conhecimento prévio, concentração e dificuldade da prova também podem influenciar o resultado.

O que a regressão procura resumir

Uma tendência **média**: como as notas costumam variar quando mudam as horas de estudo.

A distância de cada nota a essa tendência não desaparece ao estimar uma reta.

$$E(Y | X = x) = \beta_0 + \beta_1 x.$$

Lê-se: média de Y entre os casos em que $X = x$. A barra $|$ significa “dado que”.

Prever uma média não é prometer um resultado individual. A reta descreve uma tendência, não uma relação determinística.

Referências: Gujarati e Porter (2011), cap. 2; Anderson et al. (2021), cap. 14.

A reta da amostra é a mesma da população?

FRP: função de regressão populacional; **FRA**: função de regressão amostral. O índice i identifica a observação.

População: FRP

$$Y_i = \beta_0 + \beta_1 X_i + u_i, \quad E(u_i | X_i) = 0.$$

- β_0 : intercepto populacional.
- β_1 : inclinação populacional.
- u_i : erro não observado; $E(u_i | X_i) = 0$ significa média zero em cada valor de X .

Amostra: FRA

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i, \quad e_i = y_i - \hat{y}_i.$$

- $\hat{\beta}_0, \hat{\beta}_1$: coeficientes estimados; o chapéu indica estimação.
- $\hat{y}_i$: valor ajustado.
- e_i : resíduo calculado; também escrito como $\hat{u}_i$ em econometria.

Observado = ajustado + resíduo. Resíduo positivo: o modelo subestimou aquela observação.

Erros que se cancelam significam uma boa previsão?

Imagine dois resíduos

A reta errou um ponto para baixo em uma observação e um ponto para cima em outra.

$$(-1) + (+1) = 0.$$

A soma é zero, mas **houve erro nas duas previsões.**

Como evitar o cancelamento?

Elevando os resíduos ao quadrado:

$$(-1)^2 + (+1)^2 = 2.$$

MQO escolhe os coeficientes que tornam a soma dos quadrados **a menor possível.**

$$\text{SQRes} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)]^2.$$

Mínimos quadrados ordinários (MQO) compara o erro total das retas, não quantos pontos cada uma acerta exatamente. Requer variação em x ; ajustar não substitui diagnosticar.

Calculando a inclinação: covariância dividida pela variância de X

i	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	1	2	-2	-2	4	4
2	2	4	-1	0	0	1
3	3	5	0	1	0	0
4	4	4	1	0	0	1
5	5	5	2	1	2	4
Soma			0	0	6	10


$$\hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} = \frac{6}{10} = 0,6.$$

O numerador mede quanto X e Y variam juntos; o denominador, quanto X varia. A inclinação é positiva porque a covariação é positiva.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2-3.

Por que a reta passa pelo ponto das médias?



$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 4 - 0,6 \cdot 3 = 2,2.$$

$$\hat{y} = 2,2 + 0,6x$$

Inclinação: 1 hora adicional está associada a 0,6 ponto a mais na nota prevista.

Intercepto: previsão formal de 2,2 pontos em $x = 0$, fora da faixa observada de 1 a 5 horas.

Em $x = \bar{x}$: $\hat{y} = (\bar{y} - \hat{\beta}_1 \bar{x}) + \hat{\beta}_1 \bar{x} = \bar{y}$. Por isso, a reta de MQO **com intercepto** sempre passa pelas médias amostrais.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–3.

A reta superestimou ou subestimou a nota?

Para três horas de estudo, a reta prevê 4 pontos; a nota observada foi 5. Qual é o sentido do erro?

i	x_i	y_i	$\hat{y}_i = 2,2 + 0,6x_i$	$e_i = y_i - \hat{y}_i$	e_i^2
1	1	2	2,8	-0,8	0,64
2	2	4	3,4	0,6	0,36
3	3	5	4,0	1,0	1,00
4	4	4	4,6	-0,6	0,36
5	5	5	5,2	-0,2	0,04
Soma				0	2,40

$$e_3 = 5 - 4 = 1, \quad \text{SQRes} = \sum_i e_i^2 = 2,40.$$

Somar resíduos permitiria cancelar erros de sinais opostos. MQO minimiza sua **soma de quadrados**; isso não significa acertar cada observação.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2-3.

A associação muda se horas virarem minutos?

$$\hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} = \frac{s_{xy}}{s_x^2} = r \frac{s_y}{s_x}.$$

No exemplo de cinco pontos

$$s_{xy} = \frac{6}{4} = 1,5, \quad s_x^2 = \frac{10}{4} = 2,5.$$

$$\hat{\beta}_1 = \frac{1,5}{2,5} = 0,6.$$

Como $s_y = \sqrt{1,5}$ e $s_x = \sqrt{2,5}$, também temos $r \approx 0,7746$.

As unidades importam

r não tem unidade; $\hat{\beta}_1$ é medido em pontos por hora.

Se X passar de horas para minutos, a inclinação passa a

$$\frac{0,6}{60} = 0,01 \text{ ponto/minuto.}$$

A associação e as previsões não mudaram; mudou a unidade.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), caps. 3 e 14; Gujarati e Porter (2011), caps. 1-3.


Trocar X por Y muda a pergunta ou apenas o gráfico?

	Correlação	Regressão simples
Papéis de X e Y	Simétricos	Explicativa e resposta
Unidade	Nenhuma	$\hat{\beta}_1$: unidade de Y / unidade de X
Objetivo	Direção e força linear	Resposta média e previsão
Trocar X e Y	Mantém r	Muda a equação; em geral, não basta inverter a reta
Causalidade	Não implica	Também não implica por si só

Nomear X como explicativa organiza a análise; não demonstra que X causa Y . Confundimento, seleção e causalidade reversa continuam sendo possíveis.

Referências: Gujarati e Porter (2011), cap. 1; Anderson et al. (2021), caps. 3 e 14.

Podemos usar a reta onde não observamos dados?



Dentro da faixa observada:

$$x = 4,5 \Rightarrow \hat{y} = 2,2 + 0,6(4,5) = 4,90.$$

Fora da faixa: em $x = 8$, a reta daria 7 pontos, mas não temos dados ali para verificar sua continuidade.

A previsão pontual não informa, sozinha, a incerteza de uma nova observação.

A reta estima a resposta média. Valores individuais variam ao redor dela; intervalos de previsão são uma extensão posterior, distinta do IC da média.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2-3.

Uma reta pode prever quem vencerá uma corrida em 2156?



Manchete histórica de 30/09/2004:

mulheres poderiam superar homens nos 100 metros olímpicos em 2156.

A projeção prolongava tendências dos tempos vencedores de provas masculinas e femininas.


Antes de aceitar a previsão

- 1 Há observações próximas de 2156?
- 2 A melhora pode manter o mesmo ritmo indefinidamente?
- 3 Uma reta bem ajustada no passado valida uma previsão tão distante?

2156 é o ano projetado pela reportagem de 2004, não um resultado observado. A conclusão depende de extrapolar as tendências para muito além dos dados.

Referências: OpenIntro, seção 8.2; recorte original da BBC News, 30/09/2004.

Onde terminam os dados e começa a extrapolação?



Leia os eixos: ano no eixo horizontal; tempo vencedor, em segundos, no vertical. Menor tempo significa maior velocidade.

- Azul: provas masculinas; vermelho: femininas.
- Os pontos observados ficam à esquerda.
- As retas prolongadas se cruzam muito depois dos últimos pontos.

O cruzamento das retas é uma consequência do modelo, não uma observação. Um ajuste forte aos tempos passados não garante a continuidade da tendência; datas sucessivas também podem ser dependentes.

Referências: OpenIntro, seção 8.2; recorte do gráfico original "Momentous sprint at the 2156 Olympics?".

Da tabela de resumos à equação da reta

Resumo	x	y
Média	86,0118	11,3490
Desvio-padrão	3,7260	3,0992

$$r \approx -0,746858, n = 51.$$

Antes da conta: como $r < 0$ e os desvios-padrão são positivos, a inclinação deve ser negativa.

1. Encontrar a inclinação:

$$\hat{\beta}_1 = r \frac{s_y}{s_x} \approx -0,746858 \frac{3,0992}{3,7260} \approx -0,6212.$$

2. Fazer a reta passar pelo centro:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \approx 64,7810.$$

3. Escrever o ajuste:

$$\hat{y} \approx 64,7810 - 0,621217x.$$

Confira: em $x = \bar{x}$, a previsão deve ser $\bar{y}$. Use os valores não arredondados nas contas; arredonde apenas o resultado final.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2-5; OpenIntro, seção 8.2; dados: poverty.txt.

Interpretando os coeficientes no contexto


$$\widehat{\text{pobreza}} = 64,7810 - 0,621217 \cdot \text{conclusão do ensino médio.}$$

- **Inclinação:** um aumento de 1 **ponto percentual** em x está associado a uma redução média estimada de cerca de 0,62 ponto percentual em y .
- **Intercepto:** valor previsto quando $x = 0$. Esse ponto está muito fora da faixa observada; não tem interpretação substantiva útil aqui.
- Não é uma estimativa de quanto a escolarização de uma pessoa causaria mudança em sua pobreza.

Uma unidade de x significa um ponto percentual, não um aumento de 1% sobre o valor inicial. De 85% para 86%, por exemplo, o aumento é de 1 ponto percentual.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–5; OpenIntro, seção 8.2, arquivo `poverty.txt`.

Previsão e resíduo: exemplo com o Distrito de Columbia



$$x = 86,0, \quad y = 16,8.$$

$$\hat{y} \approx 11,36, \quad e = 16,8 - 11,36 = 5,44.$$

O percentual observado de pobreza foi cerca de **5,44 pontos percentuais acima** do previsto pela reta.

A distância vertical entre ponto e reta representa o resíduo.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–5; OpenIntro, seções 8.1 e 8.2.

Aplicação: previsão para a Geórgia

Dados do exemplo: $x = 85,1\%$ de conclusão do ensino médio; pobreza observada $y = 12,1\%$.

- 1 Qual é o valor previsto pela reta?
- 2 O modelo superestima ou subestima a observação?
- 3 Um aumento de 5 pontos percentuais em x corresponde a que diferença prevista em y ?

Conferência dos resultados

$$\hat{y} \approx 11,92\%, \quad e \approx 12,1 - 11,92 = 0,18 \text{ p.p.}$$

O modelo subestima levemente a observação. A diferença prevista para $\Delta x = 5$ é $5\hat{\beta}_1 \approx -3,11$ p.p., **uma associação, não um efeito causal demonstrado.**

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–5; OpenIntro, seções 8.1 e 8.2; dados: poverty.txt.

Quando podemos confiar nos testes e intervalos da reta?

- ❶ **Linearidade da média:** $E(Y | X = x) = \beta_0 + \beta_1 x$.
- ❷ **Independência dos erros:** avaliar o desenho do estudo; um gráfico isolado não a garante.
- ❸ **Variância constante:** $\text{Var}(u_i | X_i) = \sigma^2$. A dispersão do erro não muda com X .
- ❹ **Normalidade dos erros:** sustenta os testes e intervalos t exatos em pequenas amostras; avaliar resíduos e valores extremos.

A normalidade exigida é a dos **erros condicionais**, não a de X nem necessariamente a distribuição marginal de Y . Não é necessária para simplesmente calcular mínimos quadrados.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–5; OpenIntro, seções 8.2 e 8.4.

Qual é o tamanho típico do erro da reta?

$$\text{SQRes} = 2,40, \quad n = 5.$$

$$s_e = \sqrt{\frac{\text{SQRes}}{n-2}} = \sqrt{\frac{2,40}{3}} \approx 0,894 \text{ ponto.}$$

- Estimamos dois coeficientes, $\hat{\beta}_0$ e $\hat{\beta}_1$: restam $n - 2$ graus de liberdade.
- s_e estima σ , o desvio-padrão do erro u_i ; está na unidade de Y .
- Ele resume o tamanho típico dos desvios em torno da reta, não uma margem que contenha todos os erros.

Não confunda s_e com o erro-padrão da inclinação. Um descreve a dispersão dos erros do modelo; o outro, a incerteza de $\hat{\beta}_1$.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–3.

O que torna a inclinação mais ou menos precisa?

$$EP(\hat{\beta}_1) = \frac{s_e}{\sqrt{\sum_i (x_i - \bar{x})^2}} = \frac{0,8944}{\sqrt{10}} \approx 0,2828.$$

- Menos ruído residual reduz o numerador e, nas demais condições iguais, a incerteza da inclinação.
- Mais dispersão informativa de X aumenta o denominador.
- Mais observações bem coletadas normalmente ampliam a informação disponível.
- Essas fórmulas são as clássicas, sob as condições de independência e variância constante dos erros.

Uma inclinação de 0,6 com EP de 0,283 contém mais informação que o número 0,6 isolado. EP também aparece como *SE*, de *standard error*, nas saídas de software.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), cap. 3.

A inclinação observada poderia ocorrer com inclinação zero?

$$H_0 : \beta_1 = 0, \quad H_1 : \beta_1 \neq 0.$$

Teste bilateral

$$t = \frac{\hat{\beta}_1 - 0}{\text{EP}(\hat{\beta}_1)}, \quad \text{gl} = n - 2.$$

$$\text{valor-p} = 2P(T_{n-2} \geq |t|).$$

t é o valor calculado. Sob H_0 , a referência é uma variável T_{n-2} com distribuição t de $n - 2$ gl.

Intervalo de confiança

$$\text{IC}_{95\%}(\beta_1) : \hat{\beta}_1 \pm t_{n-2}^* \text{EP}(\hat{\beta}_1).$$

t_{n-2}^* é o valor crítico para 95% e $n - 2$ gl.
Excluir zero do IC equivale a rejeitar o teste bilateral correspondente a 5%.

As hipóteses tratam do parâmetro populacional β_1 , não de testar se o número já calculado $\hat{\beta}_1$ é zero.

Cinco pontos: da inclinação ao teste t e ao valor-p

$$H_0 : \beta_1 = 0, \quad H_1 : \beta_1 \neq 0.$$

$$t = \frac{0,6}{0,28284} \approx 2,121, \quad \text{gl} = 5 - 2 = 3.$$

$$\text{valor-p} = 2P(T_3 \geq 2,121) \approx 0,124.$$

- Com $\alpha = 5\%$ previamente escolhido, não rejeitaríamos H_0 . O resultado não estabelece inclinação populacional diferente de zero sob esse nível.
- O valor-p combina tamanho da estimativa e sua incerteza; não mede importância prática nem prova causalidade.

Com apenas cinco observações, é difícil avaliar as hipóteses do modelo. Um valor-p pequeno não comprova que essas hipóteses sejam válidas.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), cap. 5; contas sob as hipóteses clássicas.

Quais valores da inclinação são compatíveis com os dados?

$$\hat{\beta}_1 \pm t_3^* \text{EP}(\hat{\beta}_1) = 0,6 \pm 3,18245 \cdot 0,28284.$$

$$\text{IC}_{95\%}(\beta_1) \approx [-0,300; 1,500]$$

- O intervalo inclui zero, em concordância com o teste bilateral a 5%.
- Inclinações entre cerca de $-0,30$ e $1,50$ ponto por hora são compatíveis com esse intervalo, sob o modelo.
- A amostra é pequena e o resultado é **impreciso**: o intervalo é largo.

Uma amostra pequena pode deixar grande incerteza sobre a magnitude da associação, mesmo quando a inclinação estimada é positiva.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), cap. 5.

Teste e intervalo da inclinação: uma conta completa

Exercício condicionado às hipóteses clássicas: use o ajuste de pobreza e escolaridade. As contas abaixo não validam a independência entre estados.

1. Testar se a inclinação é zero

$$H_0 : \beta_1 = 0, \quad H_1 : \beta_1 \neq 0.$$

$$\hat{\beta}_1 = -0,6212, \quad EP(\hat{\beta}_1) = 0,0790.$$

$$t \approx \frac{-0,6212}{0,0790} \approx -7,86, \quad gl = 51 - 2 = 49.$$

Sob esse modelo, valor-p $< 0,001$.

2. Quantificar a associação

Para 95% de confiança, $t_{49}^* \approx 2,010$:


$$-0,6212 \pm 2,010 \cdot 0,0790$$

$$\approx [-0,780; -0,462].$$

O intervalo exclui zero e contém apenas inclinações negativas; a associação estimada é uma redução de 0,46 a 0,78 p.p. em y por 1 p.p. em x .

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–5; OpenIntro, método da seção 8.4 aplicado aos dados da seção 8.2; interpretação não causal.

Resíduos das notas: o modelo deixou um padrão?




- Em $\hat{y} = 4$, o resíduo é $+1$: o observado está acima da reta.
- Em $\hat{y} = 4,6$, o resíduo é $-0,6$: o observado está abaixo.
- Pergunte se sobrou curvatura, variação da dispersão ou algum ponto isolado.

Cinco resíduos não permitem verificar com segurança normalidade, independência ou variância constante. Não encontrar um padrão evidente não comprova que o modelo seja adequado.


Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 3–4.


Que sinais nos resíduos colocam a reta em dúvida?



A forma linear pode estar omitindo uma relação curva.



A variância dos erros pode mudar ao longo dos valores ajustados.




Investigue o registro, o contexto e a influência sobre a reta.

Esquemas ilustrativos, não os resíduos do exemplo anterior. Padrões são pistas para investigação, não regras automáticas de exclusão ou aprovação.

Referências: Anderson et al. (2021), cap. 14; esquemas ilustrativos.

Diagnóstico: o que procurar no gráfico de resíduos?




- **Curvatura:** a média pode não ser linear em x .
- **Formato de funil:** a variância pode mudar com x .
- **Pontos afastados:** investigar observações atípicas.
- **Padrões no tempo/espaco:** podem indicar dependência.

Idealmente, os resíduos oscilam em torno de zero sem estrutura sistemática evidente.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–5; OpenIntro, seção 8.2.

Uma única observação pode mudar nossa conclusão?



- **Resíduo grande:** valor de y incomum para aquele x .
- **Alta alavancagem:** valor de x distante do centro dos demais.
- **Influência:** a retirada do ponto altera substancialmente o ajuste.

Compare ajustes com e sem o ponto, investigue sua origem e documente decisões. Não exclua observações apenas para melhorar o resultado.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–5; OpenIntro, seção 8.3.

Errar pouco é o mesmo que explicar muita variação?

Dispersão residual: s_e

Quão longe as observações ficam da reta, na unidade de Y ?

$$s_e \approx 0,894 \text{ ponto.}$$

Um erro aceitável depende da escala e da finalidade da previsão.

Proporção explicada: R^2

Quanto da variação observada em Y é reproduzido pelo ajuste, em comparação com prever apenas $\bar{y}$?

É uma proporção sem unidade; não é uma medida em pontos ou em reais.

Também são distintas de $EP(\hat{\beta}_1)$, que mede a incerteza da inclinação. Não substitua diagnóstico, precisão e ajuste por um único número.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), cap. 3.

Quanto da variação fica na reta e quanto sobra nos resíduos?

$$y_i - \bar{y} = (\hat{y}_i - \bar{y}) + (y_i - \hat{y}_i).$$

Para MQO com intercepto, a soma dos produtos cruzados é zero; por isso:

$$\boxed{SQT = SQReg + SQRes}$$

Sigla adotada	Soma de quadrados	Interpretação
SQT	$\sum_i (y_i - \bar{y})^2$	Total: em torno da média
SQReg	$\sum_i (\hat{y}_i - \bar{y})^2$	Explicada pela regressão
SQRes	$\sum_i (y_i - \hat{y}_i)^2$	Residual: não explicada

A notação varia entre livros e softwares. Aqui, **SQReg** é a **parcela explicada** e **SQRes** é a **residual**. A identidade não vale para qualquer reta escolhida arbitrariamente.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), cap. 3.

A partição da variância e a “armadilha” das siglas

Comparando as nomenclaturas entre os livros da disciplina

Decomposição em somas de quadrados: MQO com intercepto

Variação total = Variação explicada + Variação residual.

Livro / referência	Total	Explicada	Residual (erro)	Equação fundamental
Gujarati	STQ	SQE	SQR	$STQ = SQE + SQR$
Wooldridge	SQT	SQE	SQR	$SQT = SQE + SQR$
Bussab & Morettin	SQTot	SQReg	SQRes	$SQTot = SQReg + SQRes$
Anderson et al.	SQT	SQR	SQE	$SQT = SQR + SQE$
OpenIntro (inglês)	SST	SSR	SSE	$SST = SSR + SSE$

Cuidado com as colisões de letras!

- Gujarati/Wooldridge: **E** = explicada; **R** = resíduo.
- Anderson/OpenIntro: **E** = erro; **R** = regressão (explicada).


Confira a definição no livro consultado. Nos cálculos: **SQT** = total, **SQReg** = regressão e **SQRes** = resíduos.

A reta melhora a previsão de usar sempre a média?

$$SQT = (2 - 4)^2 + (4 - 4)^2 + (5 - 4)^2 + (4 - 4)^2 + (5 - 4)^2 = 6.$$

$$SQRes = 2,40, \quad SQReg = SQT - SQRes = 6 - 2,40 = 3,60.$$

Total: $SQT = 6$ pontos ao quadrado



Prever sempre a média produz soma de quadrados 6. A reta reduz essa soma para 2,40; a redução de 3,60 mede o ganho de ajuste em relação à média.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2-3.

Que proporção da variação a reta consegue explicar?

Horas de estudo e notas

$$R^2 = 1 - \frac{2,40}{6} = 0,60.$$

60% da variação **observada nas notas da amostra** é explicada pela reta ajustada em função das horas de estudo.

Aplicação: pobreza e escolaridade

No conjunto de estados e DC:

$$R^2 \approx 0,558.$$

Cerca de 55,8% da variação observada no percentual de pobreza é explicada pelo ajuste linear com escolaridade.

$$R^2 = \frac{SQReg}{SQT} = 1 - \frac{SQRes}{SQT} \quad (SQT > 0).$$

Não significa acertar 60% das notas ou 55,8% das previsões. O objeto explicado é a **variabilidade de Y**, não uma porcentagem de observações corretas.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), cap. 3; aplicação: OpenIntro, seção 8.2.

Uma correlação negativa significa um ajuste pior?

$$r = +0,90 \text{ ou } r = -0,90 \Rightarrow R^2 = 0,81.$$


- O sinal desaparece ao elevar ao quadrado: a direção continua sendo informada por r ou $\hat{\beta}_1$.
- A identidade se aplica à regressão simples por MQO **com intercepto**; não a transporte automaticamente para outros modelos.
- R^2 não prova causalidade nem verifica linearidade, independência ou ausência de pontos influentes.
- Significância também depende do tamanho amostral e das hipóteses do teste; R^2 isolado não encerra a análise.

$$R^2 = r_{XY}^2.$$

Em uma amostra pequena, R^2 alto pode coexistir com um intervalo largo para a inclinação. No exemplo de cinco pontos, a incerteza da inclinação continua ampla.

Uma relação entre bairros descreve cada morador?

Caso de Los Angeles: o material compara 100 áreas de código postal, não 100 pessoas.



Eixo horizontal: percentual de residentes hispânicos na área.

Eixo vertical: percentual de residentes com formação superior.

O gráfico mostra associação negativa **entre as áreas observadas**. Não informa a escolaridade de cada pessoa nem demonstra uma causa.

Um coeficiente não identifica mecanismos por si só. Renda, acesso à educação e composição dos bairros são possíveis questões a investigar, não explicações comprovadas por esse gráfico. A seleção e a dependência espacial também importam.

Referências: OpenIntro, seção 8.4, áreas de código postal de Los Angeles; figura original.

Limites: extrapolação, causalidade e unidade de análise

- **Extrapolação:** prever fora da faixa observada de x depende de uma continuidade da relação que os dados não verificam.
- **Causalidade:** um coeficiente significativo não elimina confundimento nem transforma um estudo observacional em experimento.
- **Unidade de análise:** relações entre estados não permitem concluir automaticamente a mesma relação entre pessoas.
- **Generalização:** os 50 estados e DC não são uma amostra aleatória de indivíduos; inferência exige explicitar a população ou o modelo de interesse.

R^2 alto não garante boas previsões futuras, causalidade ou validade fora do contexto analisado.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 2–5; OpenIntro, seções 1.2, 8.2 e 8.4; discussão aplicada ao exemplo do material.

Como ler uma saída de regressão sem depender do software

Elemento	Pergunta respondida
$\hat{\beta}_1$	Quanto a resposta média prevista muda por unidade adicional de X ?
$\hat{\beta}_0$	Qual a previsão em $X = 0$? Esse ponto é substantivamente relevante?
$EP(\hat{\beta}_1)$	Quão incerta é a estimativa da inclinação?
Valor-p / IC	Há evidência contra o valor testado? Quais magnitudes são compatíveis com o intervalo?
s_e	Qual a dispersão residual, na unidade da resposta?
Resíduos	O modelo deixou padrões ou observações influentes para investigar?
R^2	Que proporção da variação observada de Y o ajuste reproduz?

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 3–5.

Checagem de 1.3: estimação, inferência e ajuste

Tente responder	Confira o conceito
Qual a diferença entre u_i e e_i ?	Erro não observado do modelo versus resíduo calculado após o ajuste.
O que MQO minimiza?	$SQ_{Res} = \sum_i e_i^2$, não a soma simples de resíduos.
De reais para milhares de reais em X ?	A inclinação é multiplicada por 1000; as previsões não mudam.
valor- $p < 0,05$ implica efeito grande ou causal?	Não: significância, magnitude e causalidade são questões diferentes.
Por que avaliar s_e e R^2 ?	Um mede dispersão na unidade de Y ; o outro, ajuste relativo à variação total.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 1–5.

Questão-síntese: regressão em Ciências Contábeis

Suponha uma base com **19 empresas** e o seguinte ajuste de regressão simples com intercepto:

$$\widehat{ROA} = 2,1 + 0,35 \text{ MargemBruta.}$$

$$n = 19, \quad EP(\hat{\beta}_1) = 0,10, \quad \text{valor-p} \approx 0,003, \quad R^2 \approx 0,42.$$

ROA e margem bruta estão em **porcentagem**; suas diferenças são medidas em pontos percentuais.

Explique em linguagem comum

- 1 O que representa a inclinação 0,35?
- 2 O que o valor-p diz e o que não diz?
- 3 Como interpretar $R^2 \approx 0,42$?
- 4 Por que nenhum desses números prova causalidade?

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), cap. 5.

Conferência: magnitude, incerteza, ajuste e causalidade

- ❶ **Magnitude:** 1 ponto percentual a mais de margem bruta está associado a 0,35 ponto percentual a mais no ROA previsto, em média.
- ❷ **Evidência:** se a inclinação populacional fosse zero e o modelo do teste válido, uma estatística tão ou mais extrema seria pouco provável; valor- $p \approx 0,003$. Isso não é a probabilidade de a hipótese ser verdadeira.
- ❸ **Ajuste:** cerca de 42% da variação observada no ROA da amostra é explicada pela relação linear estimada com a margem bruta.
- ❹ **Causalidade:** porte, setor e outras variáveis podem afetar ambos os indicadores. É necessário avaliar desenho, confundimento e especificação.

Uma boa interpretação separa esses quatro elementos e ainda examina os resíduos e a faixa de validade da previsão.

Exemplo didático; não se trata de uma base de dados real.

Referências: Anderson et al. (2021), cap. 14; Gujarati e Porter (2011), caps. 1 e 5.

Do dado bruto à interpretação: etapas de uma análise

- 1 Identificar elementos, variáveis, escalas e estrutura dos dados.
- 2 Visualizar distribuições e associações; resumir centro, dispersão e covariação.
- 3 Reconhecer a incerteza: distribuição amostral, erro-padrão, IC e teste.
- 4 Ajustar $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ por MQO e interpretar os coeficientes nas unidades corretas.
- 5 Examinar resíduos, independência, forma funcional e observações influentes.
- 6 Avaliar magnitude, precisão, erro residual, R^2 e limites das conclusões.

O critério não é simplesmente obter um valor-p pequeno ou um R^2 alto: é produzir uma interpretação defensável dos dados.

Referências: Anderson et al. (2021), caps. 1–3, 7–9 e 14; Gujarati e Porter (2011), caps. 1–5.

Referências básicas: Anderson e Gujarati

- ANDERSON, D. R.; SWEENEY, D. J.; WILLIAMS, T. A.; CAMM, J. D.; COCHRAN, J. J. *Estatística aplicada à administração e economia*. Edição completa, tradução da 8ª edição norte-americana. Cengage, 2021.
Base principal: capítulos 1–3, 7–9 e 14.
- GUJARATI, D. N.; PORTER, D. C. *Econometria Básica*. 5. ed. Porto Alegre: AMGH, 2011.
Complemento: capítulos 1–5 e Apêndice A.

Para aprofundar: Anderson organiza os métodos estatísticos; Gujarati e Porter desenvolvem a interpretação dos modelos econométricos.

OpenIntro Statistics, 4ª edição. Slides desenvolvidos por Mine Çetinkaya-Rundel/OpenIntro.

- Figuras e casos: corrida, Literary Digest, gel energético, Titanic, promoções, ketchup, pesquisa sobre empregos, energia solar, fluxo de veículos, pobreza/escolaridade e áreas de Los Angeles.
- A analogia da sopa vem do OpenIntro. Os recortes mantêm os créditos originais, incluindo Gretchen Reynolds, David De Lossy/Getty Images, Pew Research e BBC News; a projeção olímpica é uma notícia de 2004.

Atribuição e licença do material OpenIntro reutilizado: CC BY-SA 3.0 US, mantidas para esta adaptação, observadas as ressalvas dos originais quanto a imagens de terceiros.

Da descrição dos dados à regressão

**Primeiro compreender a variação;
depois modelá-la.**